Introdução ao *tidyverse*

Paulo Barros

Filosofias de código

Como em toda linguagem de programação, respeitando-se a sintaxe, existem diferentes maneiras de se resolver o mesmo problema, e também de escrever código em R.

A escolha da filosofia de cógido ou estilo de código é puramente pessoal. Há quem prefira programar usando o que chamamos de *Base R* ou R Base. Esse estilo baseia-se em utilizar puramente a sintaxe original da linguagem, não sendo dependente de pacotes que necessitem de constantes atualizações. Porém, esse também é um caminho com uma curva de aprendizado mais elevada para os que nunca tiveram contato com programação.

Uma filosofia alternativa e que hoje tem se tornado cada vez mais o padrão inicial de introdução ao R é o caminho do `tidyverse`. Um conjunto de pacotes pensado para tornar a vida do usuário de R mais fácil seus códigos mais intuitivos e legíveis.

Se você ainda não instalou este pacote pode usar

Listing 1 Instalando Pacotes

```
install.packages('tidyverse')
```

E se ainda tem dúvidas de como instalar pacotes no R dá uma olhada aqui..

Se já estiver tudo instalado podemos carregar o nosso pacote com

```
library(tidyverse)
```

Diretório de Trabalho

O diretório de trabalho é a pasta raiz na qual a sua sessão do R atual está baseada e procurará pelos arquivos de dados, e também aonde salvará arquivos gerados como resultados de alguma função.

Você pode definir o seu diretório de trabalho indo no menu *Session* > *Set Working Directory* > *Change Directory...* ou usar o atalho `CTRL + Shift + H`. Na janela que aparece a seguir, basta escolher a pasta que deseja utilizar como seu diretório de trabalho.

O passo anterior nada mais é do que uma maneira visual de invocar a função `setwd`. Esta função recebe como argumento um caminho de diretório e o define como diretório de trabalho.

> ⚠ Atenção com os caminhos de diretório!
>
> Ao definir os caminhos de diretório via código com `setwd` é importante prestar atenção a como o caminho é definido no seu sistema operacional.
> `C:\Users\SeuNome\Documents\Projeto`
> `/home/SeuNome/Documentos/Projeto`
> Note a diferença entre os usos da `\` e `/` nos diferentes sistemas. Qualquer erro na escrita do caminho acarretará em um erro na função já que não será possível encontrar o diretório especificado.
> Ao criar diretórios em seu computador evite usar caracteres especiais, nomes longos e espaços. Torne sua vida mais fácil!

Projetos em R

Um projeto em R é um arquivo com extensão `.Rproj` que mantém todos os arquivos em um diretório (scripts, dados, figuras, etc.) em um grupo. Quando criamos um projeto em R automaticamente o nosso diretório de trabalho é definido como a pasta que contém o nosso arquivo `.Rproj`. Isso facilita o trabalho colaborativo e evita problemas de definição de caminhos de arquivos.

Para criar um novo projeto voce pode acessar o menu *File* > *New Project...* ou usar o botão 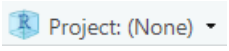

no canto superior direito do seu RStudio. Para abrir um projeto existente pode acessar *File* > *Open project...* e escolher o projeto que deseja abrir.

Quando criamos um projeto temos a opção de criar um novo diretório associado ao projeto, ou podemos usar um diretório já criado previamente e associá-lo a nosso projeto.

> **Organização é tudo!**
>
> Acostume-se a organizar o seu diretório de trabalho criando subdiretórios para armazenar os diferentes arquivos do seu projeto. Você pode por exemplo usar uma pasta para os scripts, uma para os seus dados, outras para os resultados, etc.

Entrada de Dados

No R é possível fazer o carregamento de dados nos mais diversos formatos. Os arquivos em formato de texto (`.csv`,`.txt`) são os mais compatíveis entre diferentes plataformas. Mas é possível também carregar por exemplo arquivos em formato de planilhas como `.xls` e `.xlsx`.

Embora seja possível fazer o carregamento dos arquivos de maneira visual usando o botão 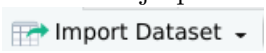

na aba *Environment*, é recomendado que você se acostume a carregar os seus dados diretamente via script uma vez que em determinadas aplicações você não terá acesso a interface do RStudio para executar um fluxo de análises em um servidor remoto por exemplo.

Importando arquivos de texto

Para importar um arquivo `.csv` é preciso ter atenção ao tipo de arquivo. CSV significa *Comma Separated Values* ou *Arquivo separado por vírgulas*, entretanto, é comum principalmente no Windows que arquivos `.csv` sejam gerados utilizando `;` como separador de campos.

Para os exemplos a seguir utilizaremos alguns conjuntos de dados de exemplo, no meu setup estes arquivos estão dentro de um diretório chamado `data`. Podemos usar o comando `list.files` para visualizar os arquivos disponíveis nessa pasta:

```
list.files(path = "data")
```

```
[1] "data_cows.txt"       "dietas_galinha.xlsx" "NELP365.csv"
[4] "NELP550.csv"         "NELPN.csv"           "Peso365.csv"
```

O argumento `path` informa em qual pasta desejo listar os meus arquivos, se omitirmos esse argumento o comando fará a busca no diretório raiz que está setado como diretório de trabalho na sessão atual.

Você pode consultar qual diretório é o atual de trabalho com o comando `getwd`:

```
getwd()
```

```
[1] "/home/paulo/Insync/pbarrosbio@gmail.com/Google
Drive/PROJECTS/intro_r_tidyverse"
```

Vamos importar o arquivo `Peso365.csv`, este é um arquivo `.csv` padrão que tem os campos separados por vírgulas. Você pode abrir o arquivo para inspecioná-lo em um editor de texto por exemplo.

```
p365 <- read.csv(file = "data/Peso365.csv")
```

No comando acima estamos fazendo a leitura do nosso arquivo e armazenando em um objeto chamado `p365`. Podemos testar se a nossa importação foi bem sucedida pedindo para exibir as linhas iniciais e finais do nosso arquivo com os comandos `head` e `tail` respectivamente.

```
head(p365)
```

```
  Animal Pai P365
1      1   A  322
2      2   A  324
3      3   A  321
4      4   A  330
5      5   A  327
6      6   A  325
```

```
tail(p365)
```

```
   Animal Pai P365
31     31   F  311
32     32   F  333
33     33   F  317
34     34   F  315
35     35   F  330
36     36   F  318
```

> Perguntar não custa nada!
>
> Lembre-se que você pode pedir ajuda ao R sobre qualquer função.
> `help(head)` `help(tail)`

Nem todo arquivo de texto é separado por algum caracter especial, alguns utilizam espaços ou tabulações para separar os campos. Agora iremos importar o arquivo `data_cows.txt`.

```
cows <- read.table(file = "data/data_cows.txt",
                   header = TRUE)
```

Observe que neste caso precisamos informar o argumento `header` que indica para a função se o nosso arquivo possui um cabeçalho de colunas ou não. Esse é um detalhe importante na hora de importar arquivos no R, uma vez que se não informamos a presença de uma linha de cabeçalho a função criará novos nomes para as colunas e a linha de cabeçalho sera interpretada como uma linha de dados.

```
head(cows)
```

```
  animal   iron      infect weight day
1    A01 NoIron NonInfected    110 122
2    A01 NoIron NonInfected    135 150
3    A01 NoIron NonInfected    150 166
4    A01 NoIron NonInfected    160 179
5    A01 NoIron NonInfected    170 219
6    A01 NoIron NonInfected    175 247
```

```
tail(cows)
```

```
    animal iron   infect weight day
593    A26 Iron Infected    325 627
594    A26 Iron Infected    325 655
595    A26 Iron Infected    325 668
596    A26 Iron Infected    340 723
597    A26 Iron Infected    335 751
598    A26 Iron Infected    345 781
```

Importando arquivos de Excel

Para importar arquivos no formato do Excel é necessário a utilização do pacote `readxl`. Se não tiver instalado faça a instalação:

```
install.packages("readxl")
```

Uma vez instalado podemos carregaro pacote e fazer a importação do nosso arquivo `dietas_galinhas.xslx`.

```r
library(readxl)

galinhas <- read_xlsx(path = "data/dietas_galinha.xlsx")
```

```r
head(galinhas)
```

```
# A tibble: 6 x 6
    rep `Dieta A` `Dieta B` `Dieta C` `Dieta D` `Dieta E`
  <dbl>     <dbl>     <dbl>     <dbl>     <dbl>     <dbl>
1     1       179       309       243       423       368
2     2       160       229       230       340       390
3     3       136       181       248       392       379
4     4       227       141       327       339       260
5     5       217       260       329       341       404
6     6       168       203       250       226       318
```

```r
tail(galinhas)
```

```
# A tibble: 6 x 6
    rep `Dieta A` `Dieta B` `Dieta C` `Dieta D` `Dieta E`
  <dbl>     <dbl>     <dbl>     <dbl>     <dbl>     <dbl>
1     1       179       309       243       423       368
2     2       160       229       230       340       390
3     3       136       181       248       392       379
4     4       227       141       327       339       260
5     5       217       260       329       341       404
6     6       168       203       250       226       318
```

Alguns comandos úteis

Alguns comandos básicos são bastante úteis para verificar a sanidade dos dados na hora da importação. Se você olhar na sua aba *Environment* vai perceber que todos os objetos que criamos ao importar os dados agora estão listados.

Podemos visualizar os nossos dados dando um duplo clique sobre o objeto desejado ou usando a função `View`. Isso abrirá nosso conjunto de dados no visualizador do RStudio.

```r
View(p365)
```

> ⚠ Atenção!
>
> Cuidado ao tentar visualizar conjuntos de dados muito grandes, isso pode consumir uma quantidade significativa de memória e até mesmo causar uma parada da sua sessão no R.

Alguns outros comandos úteis incluem:

```
# Exibe os nomes das colunas de um data.frame

names(p365)
```

```
[1] "Animal" "Pai"    "P365"
```

```
# Exibe informações sobre a estrutura do conjunto de dados

str(galinhas)
```

```
tibble [6 x 6] (S3: tbl_df/tbl/data.frame)
 $ rep    : num [1:6] 1 2 3 4 5 6
 $ Dieta A: num [1:6] 179 160 136 227 217 168
 $ Dieta B: num [1:6] 309 229 181 141 260 203
 $ Dieta C: num [1:6] 243 230 248 327 329 250
 $ Dieta D: num [1:6] 423 340 392 339 341 226
 $ Dieta E: num [1:6] 368 390 379 260 404 318
```

```
# Exibe o tipo de objeto

class(p365)
```

```
[1] "data.frame"
```

```
class(galinhas)
```

```
[1] "tbl_df"     "tbl"        "data.frame"
```

Percebeu a diferença entre o tipo de objeto `p365` e `galinhas`? O primeiro é do tipo `data.frame` que é o objeto padrão de tabelas do R. O segundo é do tipo `tbl_df` que é um tipo especial de `data.frame` com algumas melhorias. A este tipo de tabela é chamada de `tibble`, e é o formato padrão de tabelas utilizados pelo pacote `tidyverse`. A partir daqui comecaremos a utilizar as funções deste pacote, então se ainda não instalou veja o código em Listing 1.

Selecionando variáveis

Se ainda não carregou o `tidyverse` a hora é agora.

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0
--
v dplyr     1.1.4     v readr     2.1.5
v forcats   1.0.0     v stringr   1.5.1
v ggplot2   3.5.1     v tibble    3.2.1
v lubridate 1.9.3     v tidyr     1.3.1
v purrr     1.0.2
-- Conflicts ------------------------------------------ tidyverse_conflicts()
--
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors
```

Seleção de variáveis é uma das tarefas mais triviais na edição de dados. Muitas das vezes precisamos fazer recortes nos dados, ou selecionar um conjunto específico de variáveis ou até mesmo uma única variável para executar operações.

Para isso podemos utilizar a função `select` que é parte do pacote `dplyr`, um dos componentes do `tidyverse`. Vamos relembrar os nomes das nossas colunas no dataset `galinhas`

```
names(galinhas)
```

```
[1] "rep"     "Dieta A" "Dieta B" "Dieta C" "Dieta D" "Dieta E"
```

```
select(galinhas,"Dieta A","Dieta C","Dieta E")
```

```
# A tibble: 6 x 3
  `Dieta A` `Dieta C` `Dieta E`
      <dbl>     <dbl>     <dbl>
1       179       243       368
2       160       230       390
3       136       248       379
4       227       327       260
5       217       329       404
6       168       250       318
```

Observe que na hora de informar as colunas a selecionar eu precisei usar "" já no nome das variáveis existe um espaço sendo usado. Por isso que é sempre recomendado evitar este tipo de nomes de variáveis, quanto mais pudermos facilitar a nossa vida melhor! Mas essa é uma boa oportunidade para apresentar mais um pacote útil.

```
install.packages("janitor")
```

O pacote `janitor` é muito útil na hora de realizar tarefas de sanitização de dados. Vamos usar esse pacote para renomear as nossas colunas de uma maneira mais legível e compatível com a sintaxe do R.

```
library(janitor)
```

```
Attaching package: 'janitor'

The following objects are masked from 'package:stats':

    chisq.test, fisher.test
```

```
clean_names(galinhas)
```

```
# A tibble: 6 x 6
    rep dieta_a dieta_b dieta_c dieta_d dieta_e
  <dbl>   <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
1     1     179     309     243     423     368
2     2     160     229     230     340     390
3     3     136     181     248     392     379
4     4     227     141     327     339     260
5     5     217     260     329     341     404
6     6     168     203     250     226     318
```

Percebam que embora tenhamos utilizado a função `clean_names` nosso conjunto de dados continua o mesmo já que não atualizamos o nosso objeto para fixar as mudanças que fizemos.

Muitas vezes não queremos alterar o nosso objeto original e podemos criar novos objetos, ou simplesmente sobrescrever o objeto antigo com o novo com as mudanças aplicadas. Vamos atualizar o nosso objeto.

```r
# limpando os nomes das colunas e sobrescrevendo o nosso objeto

galinhas <- clean_names(galinhas)

# fazendo novamente a seleção das variáveis agora com
# as colunas renomeadas

select(galinhas,dieta_a, dieta_c,dieta_e)
```

```
# A tibble: 6 x 3
  dieta_a dieta_c dieta_e
    <dbl>   <dbl>   <dbl>
1     179     243     368
2     160     230     390
3     136     248     379
4     227     327     260
5     217     329     404
6     168     250     318
```

Observem que agora que compatibilizamos o nome das nossas colunas o uso de "" não é mais necessário, podemos simplesmente passar pra função o nome das colunas.

Seleção de intervalos

Em R o caracter : é utilizado para gerar um intervalo. Por exemplo:

```r
1:10
```

```
 [1]  1  2  3  4  5  6  7  8  9 10
```

Podemos utilizar esse operador também para selecionar intervalos de colunas/variáveis:

```r
select(galinhas, dieta_a:dieta_c)
```

```
# A tibble: 6 x 3
  dieta_a dieta_b dieta_c
    <dbl>   <dbl>   <dbl>
1     179     309     243
2     160     229     230
3     136     181     248
4     227     141     327
```

```
5      217      260      329
6      168      203      250
```

O tipo de seleção com a função `select` sempre retorna um `data.frame` ou uma `tibble`. Mas podemos também querer acessar os valores de determinada coluna como um vetor. Para isso podemos usar `$` para indexar a coluna que quisermos.

```
galinhas$rep
```

```
[1] 1 2 3 4 5 6
```

```
galinhas$dieta_a
```

```
[1] 179 160 136 227 217 168
```

A notação `$` é do R Base, mas podemos realizar a mesma operação usando a função `pull` do `dplyr`.

```
pull(galinhas, rep)
```

```
[1] 1 2 3 4 5 6
```

Filtros

A função `filter` nos permite selecionar subgrupos dos nossos dados baseado em critérios fornecidos. Os filtros podem ser baseados em operadores matemáticos

- `<` menor que
- `>` maior que
- `==` igual
- `!=` diferente

ou pode também usar outras funções condicionais como `is.na()` que testa se uma variável contém dados faltantes `NA`, ou `between(a,b)` que checa se os valores estão em um determinado intevalo definido.

```
filter(p365,
       Pai == "A")
```

```
  Animal Pai P365
1      1   A  322
2      2   A  324
3      3   A  321
4      4   A  330
5      5   A  327
6      6   A  325
```

```r
summary(p365$P365)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  298.0   318.8   323.0   322.2   328.0   338.0
```

```r
filter(p365,
       between(P365, 280, 310))
```

```
  Animal Pai P365
1     19   D  306
2     23   D  300
3     24   D  298
```

Pipe

Em um fluxo de análises é comum realizarmos tarefas sequenciais. O operador *Pipe* |> nos permite combinar funções em sequência retornando ao final o objeto modificado pela série de operações que realizamos. Isso nos poupa tempo e evita que sejam criados objetos intermediários para armazenar o resultado das diversas operações.

Algumas regras são importantes de se notar:

- O |> opera da esquerda para a direita, ou seja, o nosso objeto de entrada está sempre a esquerda.

```r
# o nosso data.frame inicia a linha de código a esquerda

p365 |> head()
```

```
  Animal Pai P365
1      1   A  322
2      2   A  324
3      3   A  321
4      4   A  330
```

```
5      5   A  327
6      6   A  325
```

- O `|>` sempre é o último item em uma linha de código quando quebramos as linhas para tornar a sequência mais legível.

```
# Podemos quebrar o código em múltiplas linhas
# mas o operador de pipe sempre ao final de cada linha

p365 |>
  filter(Pai == "B" & P365 >= 320 ) |>
  pull(P365)
```

```
[1] 323 328 320 328 324 322
```

Criando ou Modificando Variáveis

A função `mutate` nos permite modificar uma variável ou criar novas variáveis, sejam elas a partir de novos valores ou derivadas de nossas variáveis originais.

Por exemplo, no dataset `p365` a variável `P365` está em Kg, podemos criar uma nova variável a partir desta que expresse o peso dos animais em arrobas (1 arroba = 15 Kg)

```
p365 |>
  mutate(P365_ARR = P365/15) |>
  head()
```

```
  Animal Pai P365 P365_ARR
1      1   A  322 21.46667
2      2   A  324 21.60000
3      3   A  321 21.40000
4      4   A  330 22.00000
5      5   A  327 21.80000
6      6   A  325 21.66667
```

Por padrão nossas novas variáveis serão incluídas ao final do nosso conjunto de dados, mas este comportamento pode ser modificado passando argumentos para a função. Quer saber como? Dá uma olhada na documentação da função usando `?mutate`.

Vale ressaltar mais uma vez que para que as mudanças sejam fixadas, precisamos ou atualizar o nosso conjunto de dados ou criar um novo objeto para salvar estas mudanças.

Duas funções muito úteis que são comumente utilizadas em conjunto com o `mutate` são `case_when` e `if_else`. Estas funções nos permite utilizar filtros ou condições para realizar

mudanças no banco de dados. São muito úteis quando precisamos criar novas variáveis como classes, ou alterar observações nos dados que estão dentro de faixas específicas de valores/classes.

Novamente, fique a vontade pra consultar a documentação destas duas funções.

Salvando dados

Como mencionado anteriormente, formatos de texto são sempre os mais compatíveis entre plataformas e portanto os mais recomendados.

As funções `write_csv` e `write.table` nos permitem salvar arquivos em `.csv` e em `.txt` respectivamente. A diferença básica entre os dois é que ao salvar em *csv* a função padroniza o arquivo separado por vírgulas. Ja em formato texto é possível definir o separador de valores do arquivo.

```
# Salvando em .csv

p365 |>
  mutate(P365_ARR = P365/15) |>
  write_csv(file = "p365_novo.csv")

# Salvando como .txt

p365 |>
  mutate(P365_ARR = P365/15) |>
  write.table(file = "p365_novo.txt")
```

Importante lembrar que os arquivos serão salvos na pasta raiz do projeto, ou no diretório configurado como diretório de trabalho.

Existe uma função `write_delim` do pacote `readr` que é similar a `write.table`, fique a vontade para explorar a documentação e comparar as características das duas funções.