

Estatísticas Descritivas

Paulo Barros

Uma parte crucial em todo fluxo de análise de dados é o que chamamos de Análise Exploratória dos Dados, ou EDA (*Exploratory Data Analysis*). Essa é uma etapa fundamental que se feita corretamente evita dores de cabeça futuras na hora das análises ou modelagem.

Parte da EDA, as Estatísticas Descritivas são obrigatórias e nos ajudam a descrever, como o próprio nome já indica, a natureza dos nossos dados. Nesta sessão vamos conhecer funções nativas do R para o cálculo de estatísticas descritivas, bem como alguns pacotes que são muito úteis e facilitam bastante a vida.

Pacotes

Nesta sessão utilizaremos três pacotes novos, o `rstatix`, `pastecs` e `DescTools`, todos com funções muito úteis para EDA. Você pode instalar os pacotes rodando o código abaixo:

```
install.packages("rstatix")
install.packages("pastecs")
install.packages("DescTools")
```

Vimos na seção de introdução que podemos usar `library()` para carregar um pacote, é como temos feito com o `tidyverse` até então por exemplo. Mas existem ocasiões nas quais não queremos ter acesso a todo o pacote, e sim a algumas funções específicas. Para isso, para evitar utilizar memória desnecessária, ao invés de carregar o pacote, podemos fazer a invocação da função diretamente com `nome_do_pacote::função`. Veremos isso na prática nesta sessão.

Medidas de Posição

Medidas de posição (ou medidas de tendência central) descrevem brevemente a localização dos dados na reta dos números reais. **Elas indicam um ponto central em torno do qual os dados tendem a se agrupar.** As medidas de posição mais importantes são a **média** e a **mediana** (Oleksy, 2018).

Média Aritmética

A média aritmética é a medida de posição mais comum. Se n é o número de observações de x_i , com $i = 1$, definimos a média como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Ou seja, a média é o somatório das observações, dividido pelo número total de observações.

No R, a função `mean()` calcula a média aritmética.

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9)

mean(obs)
```

```
[1] 11
```

No caso de dados faltantes (*missing*), geralmente representados por **NA**, precisamos informar a função para remover estes valores ao fazer o cálculo, se não fizermos isso obteremos **NA** como média, o que não está correto.

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9, NA)

mean(obs)
```

```
[1] NA
```

Para isso utilizaremos o argumento `na.rm = TRUE` na função:

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9, NA)

mean(obs, na.rm = TRUE)
```

```
[1] 11
```

Mediana

A **mediana é o valor da observação central**, quando os dados estão ordenados em ordem crescente ou decrescente. Se o número de observações (n) for ímpar, então a mediana é a observação na posição $(n + 1)/2$. Já se o número de observações for par, haverá duas observações centrais — nas posições $n/2$ e $(n/2) + 1$ — e a mediana será a média aritmética desses dois valores (Oleksy, 2018).

- Se n for ímpar:

$$\text{Mediana} = x_{(\frac{n+1}{2})}$$

- Se n for par:

$$\text{Mediana} = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}$$

Considere os valores $\{2, 8, 16, 17, 21, 33, 33, 35, 37\}$

```
obs <- c(2,8,16,17,21,33,33,35,37)
median(obs)
```

[1] 21

Quando nossa distribuição é simétrica, a média e a mediana se aproximam. Entretanto, quando temos uma distribuição assimétrica, a mediana talvez seja a medida de posição mais recomendada uma vez que 50% das observações estarão acima, e 50% abaixo da mediana.

Medidas de Dispersão

Dispersão refere-se a medidas de quão espalhados estão os dados. Geralmente, são estatísticas cujos valores próximos de zero indicam pouca dispersão (dados concentrados), e cujos valores elevados (em termos relativos) indicam que os dados estão muito dispersos (Oleksy, 2018).

As medidas de tendência (média, mediana,...) não são capazes de nos dizer nada sobre a **variabilidade** nos nossos dados.

Mínimo, Máximo e Amplitude

```
obs <- c(2,8,16,17,21,33,33,35,37)
```

```
min(obs)
```

```
[1] 2
```

```
max(obs)
```

```
[1] 37
```

```
range(obs)
```

```
[1] 2 37
```

Percebam que `range()` nos retorna os valores de Máximo e Mínimo. Se quisermos calcular o intervalo, ou a diferença entre o mínimo e o máximo, podemos lançar mão da função `diff()`.

```
diff(range(obs))
```

```
[1] 35
```

Quartis

Os quartis são medidas de posição que dividem um conjunto de dados ordenados em quatro partes iguais, cada uma contendo 25% das observações.

- **Q1** (primeiro quartil): separa os 25% menores valores. É a mediana da metade inferior dos dados.
- **Q2** (segundo quartil): é a mediana dos dados (50%). Divide o conjunto ao meio.
- **Q3** (terceiro quartil): separa os 75% menores valores. É a mediana da metade superior dos dados.

Porque usamos quartis?

- Permitem entender a distribuição dos dados.
- Ajudam a identificar dispersão e assimetria.
- São usados para calcular o intervalo interquartil (IQR), que mede a dispersão central:

$$IQR = Q3 - Q1$$

Esse intervalo cobre os 50% centrais dos dados e é útil para detectar outliers. A identificação de outliers em boxplots é feita com base no Intervalo Interquartil (IQR) usando uma regra empírica clássica.

- Limite inferior (LI):

$$LI = Q1 - 1.5 \times IQR$$

- Limite superior (LS):

$$LI = Q3 + 1.5 \times IQR$$

Qualquer valor que esteja abaixo do limite inferior ou acima do limite superior é considerado outlier.

Vamos considerar novamente nossos dados de pinguins que trabalhamos na sessão anterior. Podemos criar uma visualização que mostre a distribuição dos dados e os respectivos quartis.

```
library(tidyverse, quietly = TRUE)
library(palmerpenguins, quietly = TRUE)
```

Vamos primeiro calcular os quartis para nossa variável de `bill_length_mm`. Vamos utilizar a função `quantile()` lembrando de passar o argumento `na.rm=TRUE` para remover os dados faltantes.

```
quantile(penguins$bill_length_mm, na.rm = TRUE)
```

```
0%      25%      50%      75%     100%
32.100 39.225 44.450 48.500 59.600
```

Podemos agora salvar com algumas transformações em um objeto que usaremos na nossa visualização:

```
quartis_bico <- quantile(penguins$bill_length_mm, na.rm = TRUE) |>
  as_tibble() |>
  mutate(quartil = c("Min", "Q1", "Q2", "Q3", "Max"), .before = 1)


quartis_bico
```

```
# A tibble: 5 x 2
  quartil value
  <chr>   <dbl>
1 Min     32.1
2 Q1      39.2
3 Q2      44.4
4 Q3      48.5
5 Max     59.6
```

Vamos agora plotar um histograma, e colocar os nossos quartis pra ver como está distribuída a nossa variável:

```
ggplot(penguins,aes(x=bill_length_mm)) +
  geom_histogram(fill = "grey90",
                 color = "grey60",
                 alpha = .85,
                 bins = 45) +
  geom_vline(data = quartis_bico, aes(xintercept = value),
            linetype = 2) +
  scale_y_continuous(expand = c(0,0)) +
  annotate("text",x = quartis_bico$value -0.1, y = 25, label =
    ↪ quartis_bico$quartil,
          hjust=.5,
          vjust = 0,
          angle = 90) +
  coord_cartesian(ylim = c(0,30),clip = "off") +
  theme_classic() +
  theme(axis.title.x = element_text(margin = margin(t = 20, r = 0, b = 0, l =
    ↪ 0))) +
  labs(x = "Comprimento do Bico (mm)", y = "")
```

Warning: Removed 2 rows containing non-finite outside the scale range (`stat\_bin()`).



Comprimento do Bico (mm)

Como vimos anteriormente, o Q2 é a mediana dos dados. Será que nossa distribuição é simétrica? Podemos comparar a média com a mediana visualmente nos nossos dados e teremos uma noção da simetria de nossa distribuição.

```
media <- mean(penguins$bill_length_mm, na.rm = TRUE)


ggplot(penguins, aes(x=bill_length_mm)) +
  geom_histogram(fill = "grey90",
                 color = "grey60",
                 alpha = .85,
                 bins = 45) +
  geom_vline(data = quartis_bico, aes(xintercept = value),
             linetype = 2) +
  geom_vline(xintercept = media, linetype = 1, color = "darkblue") +
  scale_y_continuous(expand = c(0,0)) +
  annotate("text", x = quartis_bico$value + 0.2, y = 25, label =
    ↪ quartis_bico$quartil,
          hjust=.5,
          vjust = 1,
          angle = 90,
          size = 4) +
  annotate("text", x = media - 0.15, y = 25, label = "Média",
          hjust=.5,
```

```

    vjust = 0,
    angle = 90,
    size = 4,
    color = "darkblue") +
coord_cartesian(ylim = c(0,30),clip = "off") +
theme_classic() +
theme(axis.title.x = element_text(margin = margin(t = 20, r = 0, b = 0, l =
  ↪ 0))) +
labs(x = "Comprimento do Bico (mm)", y = "")

```

Warning: Removed 2 rows containing non-finite outside the scale range (`stat\_bin()`).



Como podemos ver, nossa média se aproxima bastante do nosso Q2, mostrando que nossa distribuição é bem simétrica.

Variância

A variância s^2 de uma amostra de n observações é dada por:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Quando falamos da variância populacional σ^2 temos que:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2$$

A mudança em utilizar $n-1$ no denominador da variância amostral é conhecida como **Correção de Bessel**, e visa corrigir o viés da estimativa da variância. Uma vez que por usarmos a média amostral $\bar{x}$ ao invés da média populacional μ , acabamos por subestimar a verdadeira variância, e utilizar $n-1$ aumenta ligeiramente o valor estimado por reduzir o denominador, fazendo assim que s^2 seja um **estimador não viesado** de σ^2 .

No R podemos calcular a variância utilizando a função `var()`.

```
var(penguins$flipper_length_mm, na.rm=TRUE)
```

```
[1] 197.7318
```

```
var(penguins$bill_length_mm, na.rm=TRUE)
```

```
[1] 29.80705
```

i Importante!

Vale ressaltar que como a variância é um quadrado (s^2), o valor obtido é também o quadrado da unidade de medida original. O que dificulta a interpretação em determinadas situações.

Desvio Padrão

O desvio padrão é a raiz quadrada da variância, e nos informa o quanto as observações na distribuição se desviam da média. Se não existe variabilidade numa população, logo o desvio padrão é zero.

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Podemos utilizar a função `sd()` de *standard deviation* no R para calcular o DP

```
sd(penguins$bill_length_mm, na.rm = TRUE)
```

```
[1] 5.459584
```

```
sd(penguins$flipper_length_mm, na.rm = TRUE)
```

```
[1] 14.06171
```

E agora temos a vantagem de trabalharmos na mesma unidade da medida original, facilitando bastante a interpretação.

Descrevendo Dados

Até agora vimos as funções individuais para obtermos estatísticas básicas como média, variância, desvio padrão, entre outras. Agora veremos como combinar essas funções pra que possamos sumarizar conjuntos de dados, bem como outros pacotes úteis para obtenção de estatísticas descritivas.

`summary()`

Esta função base do R nos fornece um sumário simples de um conjunto de dados como um todo, ou de uma variável específica.

```
summary(penguins)
```

species	island	bill_length_mm	bill_depth_mm
Adelie :152	Biscoe :168	Min. :32.10	Min. :13.10
Chinstrap: 68	Dream :124	1st Qu.:39.23	1st Qu.:15.60
Gentoo :124	Torgersen: 52	Median :44.45	Median :17.30
		Mean :43.92	Mean :17.15
		3rd Qu.:48.50	3rd Qu.:18.70
		Max. :59.60	Max. :21.50
		NA's :2	NA's :2

flipper_length_mm	body_mass_g	sex	year
Min. :172.0	Min. :2700	female:165	Min. :2007
1st Qu.:190.0	1st Qu.:3550	male :168	1st Qu.:2007
Median :197.0	Median :4050	NA's : 11	Median :2008
Mean :200.9	Mean :4202		Mean :2008
3rd Qu.:213.0	3rd Qu.:4750		3rd Qu.:2009
Max. :231.0	Max. :6300		Max. :2009
NA's :2	NA's :2		

```
summary(penguins$bill_length_mm)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
32.10	39.23	44.45	43.92	48.50	59.60	2

```
summarize()
```

Com o dplyr podemos utilizar a função `summarize()`

```
desc_nadadeira <- penguins |>
  select(flipper_length_mm) |>
  drop_na() |> # remove os dados faltantes NA
  summarise(media = mean(flipper_length_mm),
            dp = sd(flipper_length_mm),
            var = var(flipper_length_mm),
            min = min(flipper_length_mm),
            max = max(flipper_length_mm),
            amplitude = diff(range(flipper_length_mm)),
            n = n())

desc_nadadeira
```

```
# A tibble: 1 x 7
  media    dp  var  min  max amplitude    n
  <dbl> <dbl> <dbl> <int> <int>      <int> <int>
1  201.  14.1 198.  172  231         59  342
```

Embora seja muito simples, para múltiplas variáveis esse fluxo se torna muito repetitivo. Por isso podemos usar pacotes que já facilitam nossa vida nesse sentido.

rstatix

A função `get_summary_stats()` deste pacote nos permite calcular várias estatísticas descritivas para múltiplas variáveis de uma só vez. É uma das minhas funções favoritas em EDA.

```
penguins |>
  rstatix::get_summary_stats(bill_length_mm:body_mass_g,
                             type = "full")
```

```
# A tibble: 4 x 13
  variable      n    min    max median    q1    q3    iqr    mad    mean
  <dbl>      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 bill_len~   342   32.1   59.6   44.4   39.2   48.5  9.28e0   7.04   43.9
  5.46
2 bill_dep~   342   13.1   21.5   17.3   15.6   18.7  3.1 e0   2.22   17.2
  1.98
3 flipper_~   342  172    231    197    190    213   2.3 e1   16.3   201.
  14.1
4 body_mas~   342 2700   6300   4050   3550   4750   1.2 e3  890.   4202.
  802.
# i 2 more variables: se <dbl>, ci <dbl>
```

Recomendo que deem uma boa olhada na documentação desta função para aproveitarem todo o seu potencial. No exemplo acima eu pedi as descritivas completas com o argumento `type = full` para todas as minhas variáveis numéricas utilizando a notação de intervalo do `tidyverse` com o argumento `bill_length_mm:body_mass_g`.

Como podem ver, a função me retorna o N, mínimo, máximo, mediana, quartis, IQR, média, desvio, erro padrão da média e intervalo de confiança.

pastecs

A função `stat.desc()` nos fornece um rol completo de estatísticas descritivas para variáveis numéricas.

```
penguins |>
  select(bill_length_mm:body_mass_g) |>
  pastecs::stat.desc()
```

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
nbr.val	3.420000e+02	342.000000	3.420000e+02	3.420000e+02
nbr.null	0.000000e+00	0.000000	0.000000e+00	0.000000e+00
nbr.na	2.000000e+00	2.000000	2.000000e+00	2.000000e+00
min	3.210000e+01	13.100000	1.720000e+02	2.700000e+03
max	5.960000e+01	21.500000	2.310000e+02	6.300000e+03
range	2.750000e+01	8.400000	5.900000e+01	3.600000e+03
sum	1.502130e+04	5865.700000	6.871300e+04	1.437000e+06
median	4.445000e+01	17.300000	1.970000e+02	4.050000e+03
mean	4.392193e+01	17.1511696	2.009152e+02	4.201754e+03

SE.mean	2.952205e-01	0.1067846	7.603704e-01	4.336473e+01
CI.mean.0.95	5.806825e-01	0.2100394	1.495607e+00	8.529605e+01
var	2.980705e+01	3.8998080	1.977318e+02	6.431311e+05
std.dev	5.459584e+00	1.9747932	1.406171e+01	8.019545e+02
coef.var	1.243020e-01	0.1151404	6.998830e-02	1.908618e-01

Para alterar a notação científica no resultado podemos usar `options(scipen = 999)`

```
options(scipen = 999)
```

```
penguins |>
```

```
  select(bill_length_mm:body_mass_g) |>
```

```
paste::stat.desc()
```

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
nbr.val	342.0000000	342.0000000	342.0000000	342.0000000
nbr.null	0.0000000	0.0000000	0.0000000	0.0000000
nbr.na	2.0000000	2.0000000	2.0000000	2.0000000
min	32.1000000	13.1000000	172.0000000	2700.0000000
max	59.6000000	21.5000000	231.0000000	6300.0000000
range	27.5000000	8.4000000	59.0000000	3600.0000000
sum	15021.3000000	5865.7000000	68713.0000000	1437000.0000000
median	44.4500000	17.3000000	197.0000000	4050.0000000
mean	43.9219298	17.1511696	200.9152047	4201.7543860
SE.mean	0.2952205	0.1067846	0.7603704	43.3647348
CI.mean.0.95	0.5806825	0.2100394	1.4956068	85.2960539
var	29.8070543	3.8998080	197.7317916	643131.0773267
std.dev	5.4595837	1.9747932	14.0617137	801.9545357
coef.var	0.1243020	0.1151404	0.0699883	0.1908618

```
options(scipen = 0)
```

E se quisermos retornar a configuração padrão `options(scipen = 0)`.

Outra maneira é salvar nossas descritivas em um objeto e formatá-lo posteriormente:

```
descritivas <- penguins |>
```

```
  select(bill_length_mm:body_mass_g) |>
```

```
paste::stat.desc()
```

```
format(descritivas, scientific = FALSE, digits = 2)
```

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
nbr.val	342.00	342.00	342.00	342.00
nbr.null	0.00	0.00	0.00	0.00
nbr.na	2.00	2.00	2.00	2.00
min	32.10	13.10	172.00	2700.00
max	59.60	21.50	231.00	6300.00
range	27.50	8.40	59.00	3600.00
sum	15021.30	5865.70	68713.00	1437000.00
median	44.45	17.30	197.00	4050.00
mean	43.92	17.15	200.92	4201.75
SE.mean	0.30	0.11	0.76	43.36
CI.mean.0.95	0.58	0.21	1.50	85.30
var	29.81	3.90	197.73	643131.08
std.dev	5.46	1.97	14.06	801.95
coef.var	0.12	0.12	0.07	0.19

DescTools

De todos, o mais completo em EDA. Oferece além das estatísticas descritivas para variáveis numéricas, também contempla as categóricas. Além de fornecer ótimas visualizações das estatísticas. Pacote realmente muito bom!

```
DescTools::Desc(penguins)
```

```
Describe penguins (tbl_df, tbl, data.frame):
```

```
data frame: 344 obs. of 8 variables
  333 complete cases (96.8%)
```


Nr	Class	ColName	NAs	Levels
1	fac	species	.	(3): 1-Adelie, 2-Chinstrap, 3-Gentoo
2	fac	island	.	(3): 1-Biscoe, 2-Dream, 3-Torgersen
3	num	bill_length_mm	2 (0.6%)	
4	num	bill_depth_mm	2 (0.6%)	
5	int	flipper_length_mm	2 (0.6%)	
6	int	body_mass_g	2 (0.6%)	
7	fac	sex	11 (3.2%)	(2): 1-female, 2-male
8	int	year	.	

1 - species (factor)

length	n	NAs	unique	levels	dupes
344	344	0	3	3	y
	100.0%	0.0%			

	level	freq	perc	cumfreq	cumperc
1	Adelie	152	44.2%	152	44.2%
2	Gentoo	124	36.0%	276	80.2%
3	Chinstrap	68	19.8%	344	100.0%

1 - species (factor)



paulo/2025-05-08


2 - island (factor)

length	n	NAs	unique	levels	dupes
344	344	0	3	3	y
	100.0%	0.0%			

	level	freq	perc	cumfreq	cumperc
1	Biscoe	168	48.8%	168	48.8%
2	Dream	124	36.0%	292	84.9%

```
3 Torgersen      52 15.1%      344 100.0%
```

2 – island (factor)



paulo/2025-05-08

3 – bill_length_mm (numeric)

length	n	NAs	unique	0s	mean	meanCI'
344	342	2	164	0	43.922	43.341
	99.4%	0.6%		0.0%		44.503

.05	.10	.25	median	.75	.90	.95
35.700	36.600	39.225	44.450	48.500	50.800	51.995


range	sd	vcoef	mad	IQR	skew	kurt
27.500	5.460	0.124	7.042	9.275	0.053	-0.893

lowest : 32.1, 33.1, 33.5, 34.0, 34.1

highest: 55.1, 55.8, 55.9, 58.0, 59.6

' 95%-CI (classic)

3 – bill_length_mm (numeric)



4 – bill_depth_mm (numeric)


length	n	NAs	unique	0s	mean	meanCI'
344	342	2	80	0	17.15	16.94
	99.4%	0.6%		0.0%		17.36
.05	.10	.25	median	.75	.90	.95
13.90	14.30	15.60	17.30	18.70	19.50	20.00
range	sd	vcoef	mad	IQR	skew	kurt
8.40	1.97	0.12	2.22	3.10	-0.14	-0.92

lowest : 13.1, 13.2, 13.3, 13.4, 13.5 (2)

highest: 20.7 (3), 20.8, 21.1 (3), 21.2 (2), 21.5

' 95%-CI (classic)

4 – bill_depth_mm (numeric)



5 – flipper_length_mm (integer)


length	n	NAs	unique	0s	mean	meanCI'
344	342	2	55	0	200.92	199.42
	99.4%	0.6%		0.0%		202.41
.05	.10	.25	median	.75	.90	.95
181.00	185.00	190.00	197.00	213.00	220.90	225.00
range	sd	vcoef	mad	IQR	skew	kurt
59.00	14.06	0.07	16.31	23.00	0.34	-1.00

lowest : 172, 174, 176, 178 (4), 179

highest: 226, 228 (4), 229 (2), 230 (7), 231

' 95%-CI (classic)

5 – flipper_length_mm (integer)



6 – body_mass_g (integer)


length	n	NAs	unique	0s	mean	meanCI'
344	342	2	94	0	4'201.75	4'116.46
	99.4%	0.6%		0.0%		4'287.05
.05	.10	.25	median	.75	.90	.95
3'150.00	3'300.00	3'550.00	4'050.00	4'750.00	5'400.00	5'650.00
range	sd	vcoef	mad	IQR	skew	kurt
3'600.00	801.95	0.19	889.56	1'200.00	0.47	-0.74

lowest : 2'700, 2'850 (2), 2'900 (4), 2'925, 2'975

highest: 5'850 (3), 5'950 (2), 6'000 (2), 6'050, 6'300

' 95%-CI (classic)

6 – body_mass_g (integer)




7 – sex (factor - dichotomous)

length	n	NAs	unique
344	333	11	2
	96.8%	3.2%	

	freq	perc	lci.95	uci.95'
female	165	49.5%	44.2%	54.9%
male	168	50.5%	45.1%	55.8%

' 95%-CI (Wilson)

7 – sex (factor – dichotomous)




8 – year (integer)

length	n	NAs	unique	0s	mean	meanCI'
344	344	0	3	0	2'008.03	2'007.94
	100.0%	0.0%		0.0%		2'008.12
.05	.10	.25	median	.75	.90	.95
2'007.00	2'007.00	2'007.00	2'008.00	2'009.00	2'009.00	2'009.00
range	sd	vcoef	mad	IQR	skew	kurt
2.00	0.82	0.00	1.48	2.00	-0.05	-1.51
value	freq	perc	cumfreq	cumperc		
1 2007	110	32.0%	110	32.0%		
2 2008	114	33.1%	224	65.1%		
3 2009	120	34.9%	344	100.0%		

' 95%-CI (classic)

8 – year (integer)



Com certeza existem diversos outros pacotes que fazem as mesmas coisas ou até mais. Vale uma busca no CRAN ou na internet para encontrar pacotes que sejam adequados para seus objetivos. Se encontrar algum outro legal me avisa!

OLEKSY, A. Data Science with R. 2018.