

Correlação de Pearson

Paulo Barros

Nesta sessão vamos estudar como descrever e testar a significância das relações entre duas variáveis. Veremos uma introdução a correlação linear, variáveis independentes e dependentes e tipos de correlação. Abordaremos como calcular o coeficiente de Correlação de Pearson e como distinguir correlação e causalidade.

Correlação

Uma **correlação** é uma relação entre duas variáveis. Os dados podem ser representados por pares ordenados (x, y) , sendo x a **variável independente** (ou explanatória) e y a **variável dependente** (ou resposta). (Larson e Farber, 2023)

Um gráfico de dispersão é uma ótima ferramenta para avaliar a relação entre duas variáveis. Considere o seguinte conjunto de dados:

Table 1: Dados do PIB e da quantidade de CO₂ emitida de 10 países. Adaptado de Larson e Farber (2023)


PIB (em trilhões de dólares)	Emissões de CO ₂ (em milhões de toneladas métricas)
1,7	552,6
1,2	462,3
2,5	475,4
2,8	374,3
3,6	748,5
2,2	400,9

PIB (em trilhões de dólares)	Emissões de CO ₂ (em milhões de toneladas métricas)
0,8	253,0
1,5	318,6
2,4	496,8
5,9	1.180,6

```
dados_pib_co2 <- tibble(
  PIB = c(1.7, 1.2, 2.5, 2.8, 3.6, 2.2, 0.8, 1.5,
    ↪ 2.4, 5.9),
  CO2 = c(552.6, 462.3, 475.4, 374.3, 748.5, 400.9,
    ↪ 253.0, 318.6, 496.8, 1180.6)
)

library(ggtext)

ggplot(dados_pib_co2,
  aes(x = PIB, y = CO2)) +
  geom_point(shape = 21, size = 4, fill = "grey70",
    ↪ color = "black")+
  theme_bw(base_size = 14, base_family = "Ubuntu")
  ↪ +
  scale_x_continuous(breaks = 1:6) +
  scale_y_continuous(breaks = seq(0,1200,by =
    ↪ 200))+
  labs(title = "Relação entre PIB e a quantidade de
    ↪ CO2 emitida,
      para amostra com 10 países.",
    x = "PIB <br> (em trilhões de dólares)",
    y = "CO<sub>2</sub> <br> (em milhões de
      ↪ toneladas métricas)") +
  theme(axis.title = element_markdown())
```



Podemos observar no gráfico uma tendência. As emissões de CO₂ parecem aumentar com o aumento do PIB.

Mas não podemos garantir que a relação entre as variáveis exista simplesmente por uma inspeção visual. Para tanto precisamos de um **coeficiente de correlação** que nos forneça a informação da força e direção da correlação entre estas variáveis.

O **coeficiente de correlação** é uma medida da força e da direção de uma relação linear entre duas variáveis. O símbolo r representa o coeficiente de correlação amostral. (Larson e Farber, 2023)

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

O **coeficiente de correlação de Pearson** foi proposto por Karl Pearson no final do século XIX como **uma medida estatística da força e direção** da relação linear entre duas variáveis quantitativas. O coeficiente, geralmente representado por r , **varia entre -1 e 1**, onde valores próximos a 1 indicam uma correlação positiva forte, valores próximos a -1 indicam uma correlação negativa forte e valores próximos a 0 indicam ausência de correlação linear. A proposta de Pearson representou um avanço importante na estatística, ao permitir quantificar

relações entre variáveis de forma objetiva e padronizada, sendo amplamente utilizada até os dias atuais em diversas áreas do conhecimento.

Figura 9.4 Indicativos gráficos sobre correlação.




Figure 1: Tipos de Correlação Adaptado de Larson e Farber (2023)

Premissas da Correlação de Pearson:

1. As amostras devem ser independentes e pareadas (i.e., as duas variáveis devem ser medidas na mesma unidade amostral)
2. As unidades amostrais são selecionadas aleatoriamente
3. A relação entre as variáveis tem que ser linear

Calculando r

Mais uma vez usaremos dados do `ecodados` de (Da Silva *et al.*, 2022).

Neste exemplo, avaliaremos a correlação entre a altura do tronco e o tamanho da raiz medidos em 35 indivíduos de uma espécie vegetal arbustiva.

```
arbustos <- ecodados::correlacao  
  
arbustos |> glimpse()
```

```
Rows: 35
Columns: 2
$ Tamanho_raiz    <dbl> 10.177049, 6.622634,
7.773629, 11.055257, 4.487274, 11.~
$ Tamanho_tronco <dbl> 19.54383, 17.13558,
19.50681, 21.57085, 13.22763, 21.62~
```

Utilizaremos a função `cor.test()` explicitando que queremos o coeficiente de Pearson no argumento `method="pearson"`.

```
cor.test(arbustos$Tamanho_raiz,
         arbustos$Tamanho_tronco,
         method = "pearson")
```

Pearson's product-moment correlation

```
data:  arbustos$Tamanho_raiz and
arbustos$Tamanho_tronco
t = 11.49, df = 33, p-value = 4.474e-13
alternative hypothesis: true correlation is not
equal to 0
95 percent confidence interval:
 0.7995083 0.9457816
sample estimates:
      cor
0.8944449
```

A hipótese nula do teste é a de que as variáveis não são correlacionadas, ou seja, $H_0 : r = 0$. Olhando nosso resultado, uma vez que nosso $p\text{-value} = 4.474e-13$, rejeitamos H_0 , nossas variáveis são **positivamente** e **fortemente** correlacionadas dado o valor de $r = 0.8944449$. Podemos comunicar nossos resultados com um gráfico de dispersão.

```
`geom_smooth()` using formula = 'y ~ x'
```

```
arbustos <- ecodados::correlacao

ggplot(data = arbustos, aes(x = Tamanho_raiz,
y = Tamanho_tronco)) +
labs(x = "Tamanho da raiz (m)", y = "Altura do
  ↳ tronco (m)") +
  geom_smooth(method = lm, se = FALSE, color =
    ↳ "#3e5c76",
linetype = "solid", linewidth=0.7) +
geom_point(size = 4, shape = 21, fill = "#dc2f02",
  ↳ alpha = 0.8) +
annotate("text",
  x = 14, y = 14,
  label = "r = 0.89, P < 0.001",
  color = "black", size = 5,
  family = "Ubuntu") +

theme_classic(base_size = 14, base_family =
  ↳ "Ubuntu") +
theme(legend.position = "none")
```




Figure 2: Adaptado de Da Silva *et al.* (2022)

i Importante

A linha de tendência tracejada no gráfico é apenas para ilustrar a relação positiva entre as variáveis. Ela não é gerada pela análise de correlação, e sim por uma regressão linear que veremos em outra sessão.

DA SILVA, F. R. *et al.* **Análises ecológicas no R.** [s.l.] Clube de Autores, 2022.

LARSON, R.; FARBER, B. **Estatística aplicada: re-tratando o mundo.** [s.l.] Bookman Editora, 2023.