

Análise de Variância


Paulo Barros

A Análise de Variância (ANOVA) é uma das ferramentas estatísticas mais influentes e amplamente utilizadas **na comparação de médias entre grupos**. Seu desenvolvimento é atribuído ao estatístico britânico Ronald A. Fisher, que a introduziu na década de 1920 como parte de seus trabalhos pioneiros em experimentação agrícola. Fisher buscava uma forma eficiente de **avaliar se diferenças observadas entre médias de grupos eram estatisticamente significativas ou se poderiam ser atribuídas apenas à variação aleatória**.

A grande contribuição de Fisher foi estruturar um método baseado na **decomposição da variabilidade total dos dados em componentes atribuíveis a diferentes fontes (como tratamento e erro)**, permitindo testar hipóteses sobre diferenças entre grupos com base na **razão entre essas variâncias**. Desde então, a ANOVA tornou-se essencial em diversas áreas do conhecimento — da biologia à engenharia, das ciências sociais às ciências da saúde — sempre que se deseja comparar múltiplos grupos sob um desenho experimental ou observacional controlado.

ANOVA

Análise de variância com um fator é uma técnica de teste de hipótese usada para comparar as médias de três ou mais populações. A análise de variância geralmente é abreviada como ANOVA.



Fontes de Variação (FV)	Graus de Liberdade (GL)	Soma de Quadrados (SQ)	Quadrado
Tratamento(entre)	$p - 1$	SQ_{Trat}	S
Erro Experimental(dentro)	$n - p$	SQ_{Res}	S
Total	$n - 1$	SQ_{Total}	

Como mencionado anteriormente, a ANOVA é um teste de razão de variâncias. O que a estatística do teste avalia de maneira resumida:

$$Estatística\ do\ Teste = \frac{Varincia\ dentro\ dos\ grupos}{Varincia\ entre\ grupos}$$

A variância entre as amostras mede as diferenças relacionadas ao tratamento/efeito atuando em cada amostra. Essa variância também é conhecida como **Quadrado Médio do Tratamento**.

Já a variância dentro das amostras mede as diferenças dentro da amostra, geralmente relacionadas com o erro amostral. Essa variância também é chamada de **Quadrado Médio do Resíduo**.

A **Estatística F** é o quociente destas duas variâncias, e nossa hipótese nula na ANOVA testa se a média dos grupos é igual:

$$H_0 : \mu_1 = \mu_2 = \dots \mu_n$$

Tabela da ANOVA

Esta é a famosa tabela da ANOVA, a mesma tabela que é retornada pelas funções que utilizaremos aqui no R. As somas de quadrado podem ser obtidas como:

$$SQ_{Total} = \sum_{i=1, j=1}^{I, J} Y_{ij}^2 - \frac{\left(\sum_{i=1, j=1}^{I, J} Y_{ij} \right)^2}{IJ}$$

$$SQ_{Trat} = \sum_{i=1}^I \frac{T_i^2}{J} - \frac{\left(\sum_{i=1, j=1}^{I, J} Y_{ij} \right)^2}{IJ}$$

$$SQ_{Total} = SQ_{Trat} + SQ_{Res}$$

Premissas da ANOVA:

1. As amostras devem ser independentes
2. As unidades amostrais são selecionadas aleatoriamente
3. Distribuição normal (gaussiana) dos resíduos
4. Homogeneidade da variância

Anova de um Fator

Para nossos exemplos práticos vamos utilizar os dados do pacote `palmerpenguins`. São dados morfométricos de diferentes espécies de pinguins coletados em diferentes ilhas.

Na ANOVA de um fator testamos o efeito de uma única variável categórica (Tratamento) sobre nossa variável dependente (y).

Pergunta: Existe diferença no tamanho do bico (`bill_length_mm`) entre as diferentes espécies de pinguim?

```
penguins <- palmerpenguins::penguins
```

```
penguins |>
  head()
```

```
# A tibble: 6 x 8
  species island    bill_length_mm bill_depth_mm
  <fct>   <fct>          <dbl>         <dbl>
  <int>     <int>
1 Adelie  Torgersen          39.1           18.7
181      3750
2 Adelie  Torgersen          39.5           17.4
186      3800
3 Adelie  Torgersen          40.3           18
195      3250
```