

Estatísticas Descritivas

Paulo Barros

Uma parte crucial em todo fluxo de análise de dados é o que chamamos de Análise Exploratória dos Dados, ou EDA (*Exploratory Data Analysis*). Essa é uma etapa fundamental que se feita corretamente evita dores de cabeça futuras na hora das análises ou modelagem.

Parte da EDA, as Estatísticas Descritivas são obrigatórias e nos ajudam a descrever, como o próprio nome já indica, a natureza dos nossos dados. Nesta sessão vamos conhecer funções nativas do R para o cálculo de estatísticas descritivas, bem como alguns pacotes que são muito úteis e facilitam bastante a vida.

Pacotes

Nesta sessão utilizaremos três pacotes novos, o `rstatix`, `pastecs` e `DescTools`, todos com funções muito úteis para EDA. Você pode instalar os pacotes rodando o código abaixo:

```
install.packages("rstatix")
install.packages("pastecs")
install.packages("DescTools")
```

Vimos na seção de introdução que podemos usar `library()` para carregar um pacote, é como temos feito com o `tidyverse` até então por exemplo. Mas existem ocasiões nas quais não queremos ter acesso a todo o pacote, e sim a algumas funções específicas. Para isso, para evitar utilizar memória desnecessária, ao invés de carregar o pacote, podemos fazer a invocação da função diretamente com `nome_do_pacote::função`. Veremos isso na prática nesta sessão.

Medidas de Posição

Medidas de posição (ou medidas de tendência central) descrevem brevemente a localização dos dados na reta dos números reais. **Elas indicam um ponto central em torno do qual os dados tendem a se agrupar.** As medidas de posição mais importantes são a **média** e a **mediana** (Oleksy, 2018).

Média Aritmética

A média aritmética é a medida de posição mais comum. Se n é o número de observações de x_i , com $i = 1$, definimos a média como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Ou seja, a média é o somatório das observações, dividido pelo número total de observações.

No R, a função `mean()` calcula a média aritmética.

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9)
mean(obs)
```

```
[1] 11
```

No caso de dados faltantes (*missing*), geralmente representados por **NA**, precisamos informar a função para remover estes valores ao fazer o cálculo, se não fizermos isso obteremos **NA** como média, o que não está correto.

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9, NA)
mean(obs)
```

```
[1] NA
```

Para isso utilizaremos o argumento `na.rm = TRUE` na função:

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9, NA)
mean(obs, na.rm = TRUE)
```

```
[1] 11
```

Mediana

A **mediana** é o valor da **observação central**, quando os dados estão ordenados em ordem crescente ou decrescente. Se o número de observações (n) for ímpar, então a mediana é a observação na posição $(n + 1)/2$. Já se o número de observações for par, haverá duas observações centrais — nas posições $n/2$ e $(n/2) + 1$ — e a mediana será a média aritmética desses dois valores (Oleksy, 2018).

- Se n for ímpar:

$$\text{Mediana} = x_{(\frac{n+1}{2})}$$

- Se n for par:

$$\text{Mediana} = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}$$

Considere os valores $\{2, 8, 16, 17, 21, 33, 33, 35, 37\}$

```
obs <- c(2,8,16,17,21,33,33,35,37)
median(obs)
```

```
[1] 21
```

Quando nossa distribuição é simétrica, a média e a mediana se aproximam. Entretanto, quando temos uma distribuição assimétrica, a mediana talvez seja a medida de posição mais recomendada uma vez que 50% das observações estarão acima, e 50% abaixo da mediana.

Medidas de Dispersão

Dispersão refere-se a medidas de quão espalhados estão os dados. Geralmente, são estatísticas cujos valores próximos de zero indicam pouca dispersão (dados concentrados), e cujos valores elevados (em termos relativos) indicam que os dados estão muito dispersos (Oleksy, 2018).

As medidas de tendência (média, mediana,...) não são capazes de nos dizer nada sobre a **variabilidade** nos nossos dados.

Mínimo, Máximo e Amplitude

```
obs <- c(2,8,16,17,21,33,33,35,37)
```

```
min(obs)
```

```
[1] 2
```

```
max(obs)
```

```
[1] 37
```

```
range(obs)
```

```
[1] 2 37
```

Percebam que `range()` nos retorna os valores de Máximo e Mínimo. Se quisermos calcular o intervalo, ou a diferença entre o mínimo e o máximo, podemos lançar mão da função `diff()`.

```
diff(range(obs))
```

```
[1] 35
```

Quartis

Os quartis são medidas de posição que dividem um conjunto de dados ordenados em quatro partes iguais, cada uma contendo 25% das observações.

- **Q1** (primeiro quartil): separa os 25% menores valores. É a mediana da metade inferior dos dados.
- **Q2** (segundo quartil): é a mediana dos dados (50%). Divide o conjunto ao meio.
- **Q3** (terceiro quartil): separa os 75% menores valores. É a mediana da metade superior dos dados.

Porque usamos quartis?

- Permitem entender a distribuição dos dados.
- Ajudam a identificar dispersão e assimetria.
- São usados para calcular o intervalo interquartil (IQR), que mede a dispersão central:

$$IQR = Q3 - Q1$$

Esse intervalo cobre os 50% centrais dos dados e é útil para detectar outliers. A identificação de outliers em boxplots é feita com base no Intervalo Interquartil (IQR) usando uma regra empírica clássica.

- Limite inferior (LI):

$$LI = Q1 - 1.5 \times IQR$$

- Limite superior (LS):

$$LI = Q3 + 1.5 \times IQR$$

Qualquer valor que esteja abaixo do limite inferior ou acima do limite superior é considerado outlier.

Vamos considerar novamente nossos dados de pinguins que trabalhamos na sessão anterior. Podemos criar uma visualização que mostre a distribuição dos dados e os respectivos quartis.

```
library(tidyverse, quietly = TRUE)
library(palmerpenguins, quietly = TRUE)
```

Vamos primeiro calcular os quartis para nossa variável de `bill_length_mm`. Vamos utilizar a função `quantile()` lembrando de passar o argumento `na.rm=TRUE` para remover os dados faltantes.

```
quantile(penguins$bill_length_mm, na.rm = TRUE)
```

```
0%      25%      50%      75%     100%
32.100 39.225 44.450 48.500 59.600
```

Podemos agora salvar com algumas transformações em um objeto que usaremos na nossa visualização:

```
quartis_bico <- quantile(penguins$bill_length_mm, na.rm = TRUE) |>
  as_tibble() |>
  mutate(quartil = c("Min", "Q1", "Q2", "Q3", "Max"), .before = 1)


quartis_bico
```

```
# A tibble: 5 x 2
  quartil value
  <chr>   <dbl>
1 Min     32.1
2 Q1      39.2
3 Q2      44.4
4 Q3      48.5
5 Max     59.6
```

Vamos agora plotar um histograma, e colocar os nossos quartis pra ver como está distribuída a nossa variável:

```
ggplot(penguins,aes(x=bill_length_mm)) +
  geom_histogram(fill = "grey90",
                 color = "grey60",
                 alpha = .85,
                 bins = 45) +
  geom_vline(data = quartis_bico, aes(xintercept = value),
            linetype = 2) +
  scale_y_continuous(expand = c(0,0)) +
  annotate("text",x = quartis_bico$value -0.1, y = 25, label =
    ↪ quartis_bico$quartil,
          hjust=.5,
          vjust = 0,
          angle = 90) +
  coord_cartesian(ylim = c(0,30),clip = "off") +
  theme_classic() +
  theme(axis.title.x = element_text(margin = margin(t = 20, r = 0, b = 0, l =
    ↪ 0))) +
  labs(x = "Comprimento do Bico (mm)", y = "")
```

Warning: Removed 2 rows containing non-finite outside the scale range (`stat\_bin()`).



Comprimento do Bico (mm)

Como vimos anteriormente, o Q2 é a mediana dos dados. Será que nossa distribuição é simétrica? Podemos comparar a média com a mediana visualmente nos nossos dados e teremos uma noção da simetria de nossa distribuição.

```
media <- mean(penguins$bill_length_mm, na.rm = TRUE)


ggplot(penguins, aes(x=bill_length_mm)) +
  geom_histogram(fill = "grey90",
                 color = "grey60",
                 alpha = .85,
                 bins = 45) +
  geom_vline(data = quartis_bico, aes(xintercept = value),
             linetype = 2) +
  geom_vline(xintercept = media, linetype = 1, color = "darkblue") +
  scale_y_continuous(expand = c(0,0)) +
  annotate("text", x = quartis_bico$value + 0.2, y = 25, label =
    ↪ quartis_bico$quartil,
          hjust=.5,
          vjust = 1,
          angle = 90,
          size = 4) +
  annotate("text", x = media - 0.15, y = 25, label = "Média",
          hjust=.5,
```

```

    vjust = 0,
    angle = 90,
    size = 4,
    color = "darkblue") +
coord_cartesian(ylim = c(0,30),clip = "off") +
theme_classic() +
theme(axis.title.x = element_text(margin = margin(t = 20, r = 0, b = 0, l =
  ↪ 0))) +
labs(x = "Comprimento do Bico (mm)", y = "")

```

Warning: Removed 2 rows containing non-finite outside the scale range (`stat\_bin()`).



Como podemos ver, nossa média se aproxima bastante do nosso Q2, mostrando que nossa distribuição é bem simétrica.

Variância

A variância s^2 de uma amostra de n observações é dada por:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Quando falamos da variância populacional σ^2 temos que:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2$$

A mudança em utilizar $n-1$ no denominador da variância amostral é conhecida como **Correção de Bessel**, e visa corrigir o viés da estimativa da variância. Uma vez que por usarmos a média amostral $\bar{x}$ ao invés da média populacional μ , acabamos por subestimar a verdadeira variância, e utilizar $n-1$ aumenta ligeiramente o valor estimado por reduzir o denominador, fazendo assim que s^2 seja um **estimador não viesado** de σ^2 .

No R podemos calcular a variância utilizando a função `var()`.

```
var(penguins$flipper_length_mm, na.rm=TRUE)
```

```
[1] 197.7318
```

```
var(penguins$bill_length_mm, na.rm=TRUE)
```

```
[1] 29.80705
```

i Importante!

Vale ressaltar que como a variância é um quadrado (s^2), o valor obtido é também o quadrado da unidade de medida original. O que dificulta a interpretação em determinadas situações.

Desvio Padrão

O desvio padrão é a raiz quadrada da variância, e nos informa o quanto as observações na distribuição se desviam da média. Se não existe variabilidade numa população, logo o desvio padrão é zero.

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Podemos utilizar a função `sd()` de *standard deviation* no R para calcular o DP

```
sd(penguins$bill_length_mm, na.rm = TRUE)
```

```
[1] 5.459584
```

```
sd(penguins$flipper_length_mm, na.rm = TRUE)
```

```
[1] 14.06171
```

E agora temos a vantagem de trabalharmos na mesma unidade da medida original, facilitando bastante a interpretação.

OLEKSY, A. Data Science with R. 2018.