

# Estatísticas Descritivas

Paulo Barros

Uma parte crucial em todo fluxo de análise de dados é o que chamamos de Análise Exploratória dos Dados, ou EDA (*Exploratory Data Analysis*). Essa é uma etapa fundamental que se feita corretamente evita dores de cabeça futuras na hora das análises ou modelagem.

Parte da EDA, as Estatísticas Descritivas são obrigatórias e nos ajudam a descrever, como o próprio nome já indica, a natureza dos nossos dados. Nesta sessão vamos conhecer funções nativas do R para o cálculo de estatísticas descritivas, bem como alguns pacotes que são muito úteis e facilitam bastante a vida.

## Pacotes

Nesta sessão utilizaremos três pacotes novos, o `rstatix`, `pastecs` e `DescTools`, todos com funções muito úteis para EDA. Você pode instalar os pacotes rodando o código abaixo:

```
install.packages("rstatix")
install.packages("pastecs")
install.packages("DescTools")
```

Vimos na seção de introdução que podemos usar `library()` para carregar um pacote, é como temos feito com o `tidyverse` até então por exemplo. Mas existem ocasiões nas quais não queremos ter acesso a todo o pacote, e sim a algumas funções específicas. Para isso, para evitar utilizar memória desnecessária, ao invés de carregar o pacote, podemos fazer a invocação da função diretamente com `nome_do_pacote::função`. Veremos isso na prática nesta sessão.

## Medidas de Posição

Medidas de posição (ou medidas de tendência central) descrevem brevemente a localização dos dados na reta dos números reais. **Elas indicam um ponto central em torno do qual os dados tendem a se agrupar.** As medidas de posição mais importantes são a **média** e a **mediana** (Oleksy, 2018).

## Média Aritmética

A média aritmética é a medida de posição mais comum. Se  $n$  é o número de observações de  $x_i$ , com  $i = 1$ , definimos a média como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Ou seja, a média é o somatório das observações, dividido pelo número total de observações.

No R, a função `mean()` calcula a média aritmética.

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9)

mean(obs)
```

```
[1] 11
```

No caso de dados faltantes (*missing*), geralmente representados por **NA**, precisamos informar a função para remover estes valores ao fazer o cálculo, se não fizermos isso obteremos **NA** como média, o que não está correto.

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9, NA)

mean(obs)
```

```
[1] NA
```

Para isso utilizaremos o argumento `na.rm = TRUE` na função:

```
obs <- c(22, 0, 7, 12, 5, 33, 14, 8, 0, 9, NA)

mean(obs, na.rm = TRUE)
```

```
[1] 11
```

## Mediana

A **mediana é o valor da observação central**, quando os dados estão ordenados em ordem crescente ou decrescente. Se o número de observações ( $n$ ) for ímpar, então a mediana é a observação na posição  $(n + 1)/2$ . Já se o número de observações for par, haverá duas observações centrais — nas posições  $n/2$  e  $(n/2) + 1$  — e a mediana será a média aritmética desses dois valores (Oleksy, 2018).

- Se  $n$  for ímpar:

$$\text{Mediana} = x_{(\frac{n+1}{2})}$$

- Se  $n$  for par:

$$\text{Mediana} = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}$$

Considere os valores  $\{2, 8, 16, 17, 21, 33, 33, 35, 37\}$

```
obs <- c(2,8,16,17,21,33,33,35,37)
median(obs)
```

[1] 21

Quando nossa distribuição é simétrica, a média e a mediana se aproximam. Entretanto, quando temos uma distribuição assimétrica, a mediana talvez seja a medida de posição mais recomendada uma vez que 50% das observações estarão acima, e 50% abaixo da mediana.

## Medidas de Dispersão

Dispersão refere-se a medidas de quão espalhados estão os dados. Geralmente, são estatísticas cujos valores próximos de zero indicam pouca dispersão (dados concentrados), e cujos valores elevados (em termos relativos) indicam que os dados estão muito dispersos (Oleksy, 2018).

As medidas de tendência (média, mediana,...) não são capazes de nos dizer nada sobre a **variabilidade** nos nossos dados.

## Mínimo, Máximo e Amplitude

```
obs <- c(2,8,16,17,21,33,33,35,37)
```

```
min(obs)
```

```
[1] 2
```

```
max(obs)
```

```
[1] 37
```

```
range(obs)
```

```
[1] 2 37
```

Percebam que `range()` nos retorna os valores de Máximo e Mínimo. Se quisermos calcular o intervalo, ou a diferença entre o mínimo e o máximo, podemos lançar mão da função `diff()`.

```
diff(range(obs))
```

```
[1] 35
```

## Quartis

Os quartis são medidas de posição que dividem um conjunto de dados ordenados em quatro partes iguais, cada uma contendo 25% das observações.

- **Q1** (primeiro quartil): separa os 25% menores valores. É a mediana da metade inferior dos dados.
- **Q2** (segundo quartil): é a mediana dos dados (50%). Divide o conjunto ao meio.
- **Q3** (terceiro quartil): separa os 75% menores valores. É a mediana da metade superior dos dados.

## Porque usamos quartis?

- Permitem entender a distribuição dos dados.
- Ajudam a identificar dispersão e assimetria.
- São usados para calcular o intervalo interquartil (IQR), que mede a dispersão central:

$$IQR = Q3 - Q1$$

Esse intervalo cobre os 50% centrais dos dados e é útil para detectar outliers. A identificação de outliers em boxplots é feita com base no Intervalo Interquartil (IQR) usando uma regra empírica clássica.

- Limite inferior (LI):

$$LI = Q1 - 1.5 \times IQR$$

- Limite superior (LS):

$$LI = Q3 + 1.5 \times IQR$$

Qualquer valor que esteja abaixo do limite inferior ou acima do limite superior é considerado outlier.

Vamos considerar novamente nossos dados de pinguins que trabalhamos na sessão anterior. Podemos criar uma visualização que mostre a distribuição dos dados e os respectivos quartis.

```
library(tidyverse, quietly = TRUE)
library(palmerpenguins, quietly = TRUE)
```

Vamos primeiro calcular os quartis para nossa variável de `bill_length_mm`. Vamos utilizar a função `quantile()` lembrando de passar o argumento `na.rm=TRUE` para remover os dados faltantes.

```
quantile(penguins$bill_length_mm, na.rm = TRUE)
```

```
0%      25%      50%      75%     100%
32.100 39.225 44.450 48.500 59.600
```

Podemos agora salvar com algumas transformações em um objeto que usaremos na nossa visualização:

```
quartis_bico <- quantile(penguins$bill_length_mm, na.rm = TRUE) |>
  as_tibble() |>
  mutate(quartil = c("Min", "Q1", "Q2", "Q3", "Max"), .before = 1)


quartis_bico
```

```
# A tibble: 5 x 2
  quartil value
  <chr>   <dbl>
1 Min     32.1
2 Q1      39.2
3 Q2      44.4
4 Q3      48.5
5 Max     59.6
```

Vamos agora plotar um histograma, e colocar os nossos quartis pra ver como está distribuída a nossa variável:

```
ggplot(penguins,aes(x=bill_length_mm)) +
  geom_histogram(fill = "grey90",
                 color = "grey60",
                 alpha = .85,
                 bins = 45) +
  geom_vline(data = quartis_bico, aes(xintercept = value),
            linetype = 2) +
  scale_y_continuous(expand = c(0,0)) +
  annotate("text",x = quartis_bico$value -0.1, y = 25, label =
    ↪ quartis_bico$quartil,
          hjust=.5,
          vjust = 0,
          angle = 90) +
  coord_cartesian(ylim = c(0,30),clip = "off") +
  theme_classic() +
  theme(axis.title.x = element_text(margin = margin(t = 20, r = 0, b = 0, l =
    ↪ 0))) +
  labs(x = "Comprimento do Bico (mm)", y = "")
```

Warning: Removed 2 rows containing non-finite outside the scale range (`stat\_bin()`).



Comprimento do Bico (mm)

Como vimos anteriormente, o Q2 é a mediana dos dados. Será que nossa distribuição é simétrica? Podemos comparar a média com a mediana visualmente nos nossos dados e teremos uma noção da simetria de nossa distribuição.

```
media <- mean(penguins$bill_length_mm, na.rm = TRUE)


ggplot(penguins, aes(x=bill_length_mm)) +
  geom_histogram(fill = "grey90",
                 color = "grey60",
                 alpha = .85,
                 bins = 45) +
  geom_vline(data = quartis_bico, aes(xintercept = value),
             linetype = 2) +
  geom_vline(xintercept = media, linetype = 1, color = "darkblue") +
  scale_y_continuous(expand = c(0,0)) +
  annotate("text", x = quartis_bico$value + 0.2, y = 25, label =
    ↪ quartis_bico$quartil,
          hjust=.5,
          vjust = 1,
          angle = 90,
          size = 4) +
  annotate("text", x = media - 0.15, y = 25, label = "Média",
          hjust=.5,
```

```

    vjust = 0,
    angle = 90,
    size = 4,
    color = "darkblue") +
coord_cartesian(ylim = c(0,30),clip = "off") +
theme_classic() +
theme(axis.title.x = element_text(margin = margin(t = 20, r = 0, b = 0, l =
  ↪ 0))) +
labs(x = "Comprimento do Bico (mm)", y = "")

```

Warning: Removed 2 rows containing non-finite outside the scale range (`stat\_bin()`).



Como podemos ver, nossa média se aproxima bastante do nosso Q2, mostrando que nossa distribuição é bem simétrica.

## Variância

A variância  $s^2$  de uma amostra de  $n$  observações é dada por:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$



Quando falamos da variância populacional  $\sigma^2$  temos que:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2$$

A mudança em utilizar  $n-1$  no denominador da variância amostral é conhecida como **Correção de Bessel**, e visa corrigir o viés da estimativa da variância. Uma vez que por usarmos a média amostral  $\bar{x}$  ao invés da média populacional  $\mu$ , acabamos por subestimar a verdadeira variância, e utilizar  $n-1$  aumenta ligeiramente o valor estimado por reduzir o denominador, fazendo assim que  $s^2$  seja um **estimador não viesado** de  $\sigma^2$ .

No R podemos calcular a variância utilizando a função `var()`.

```
var(penguins$flipper_length_mm, na.rm=TRUE)
```

```
[1] 197.7318
```

```
var(penguins$bill_length_mm, na.rm=TRUE)
```

```
[1] 29.80705
```

#### **i** Importante!

Vale ressaltar que como a variância é um quadrado ( $s^2$ ), o valor obtido é também o quadrado da unidade de medida original. O que dificulta a interpretação em determinadas situações.

## Desvio Padrão

O desvio padrão é a raiz quadrada da variância, e nos informa o quanto as observações na distribuição se desviam da média. Se não existe variabilidade numa população, logo o desvio padrão é zero.

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Podemos utilizar a função `sd()` de *standard deviation* no R para calcular o DP

```
sd(penguins$bill_length_mm, na.rm = TRUE)
```

```
[1] 5.459584
```

```
sd(penguins$flipper_length_mm, na.rm = TRUE)
```

```
[1] 14.06171
```

E agora temos a vantagem de trabalharmos na mesma unidade da medida original, facilitando bastante a interpretação.

## Descrevendo Dados

Até agora vimos as funções individuais para obtermos estatísticas básicas como média, variância, desvio padrão, entre outras. Agora veremos como combinar essas funções pra que possamos sumarizar conjuntos de dados, bem como outros pacotes úteis para obtenção de estatísticas descritivas.

### `summary()`

Esta função base do R nos fornece um sumário simples de um conjunto de dados como um todo, ou de uma variável específica.

```
summary(penguins)
```

| species       | island        | bill_length_mm | bill_depth_mm |
|---------------|---------------|----------------|---------------|
| Adelie :152   | Biscoe :168   | Min. :32.10    | Min. :13.10   |
| Chinstrap: 68 | Dream :124    | 1st Qu.:39.23  | 1st Qu.:15.60 |
| Gentoo :124   | Torgersen: 52 | Median :44.45  | Median :17.30 |
|               |               | Mean :43.92    | Mean :17.15   |
|               |               | 3rd Qu.:48.50  | 3rd Qu.:18.70 |
|               |               | Max. :59.60    | Max. :21.50   |
|               |               | NA's :2        | NA's :2       |

| flipper_length_mm | body_mass_g  | sex        | year         |
|-------------------|--------------|------------|--------------|
| Min. :172.0       | Min. :2700   | female:165 | Min. :2007   |
| 1st Qu.:190.0     | 1st Qu.:3550 | male :168  | 1st Qu.:2007 |
| Median :197.0     | Median :4050 | NA's : 11  | Median :2008 |
| Mean :200.9       | Mean :4202   |            | Mean :2008   |
| 3rd Qu.:213.0     | 3rd Qu.:4750 |            | 3rd Qu.:2009 |
| Max. :231.0       | Max. :6300   |            | Max. :2009   |
| NA's :2           | NA's :2      |            |              |

```
summary(penguins$bill_length_mm)
```

| Min.  | 1st Qu. | Median | Mean  | 3rd Qu. | Max.  | NA's |
|-------|---------|--------|-------|---------|-------|------|
| 32.10 | 39.23   | 44.45  | 43.92 | 48.50   | 59.60 | 2    |

```
summarize()
```

Com o dplyr podemos utilizar a função `summarize()`

```
desc_nadadeira <- penguins |>
  select(flipper_length_mm) |>
  drop_na() |> # remove os dados faltantes NA
  summarise(media = mean(flipper_length_mm),
            dp = sd(flipper_length_mm),
            var = var(flipper_length_mm),
            min = min(flipper_length_mm),
            max = max(flipper_length_mm),
            amplitude = diff(range(flipper_length_mm)),
            n = n())

desc_nadadeira
```

```
# A tibble: 1 x 7
  media    dp  var  min  max amplitude    n
  <dbl> <dbl> <dbl> <int> <int>      <int> <int>
1  201.  14.1 198.  172  231         59  342
```

Embora seja muito simples, para múltiplas variáveis esse fluxo se torna muito repetitivo. Por isso podemos usar pacotes que já facilitam nossa vida nesse sentido.

**rstatix**

A função `get_summary_stats()` deste pacote nos permite calcular várias estatísticas descritivas para múltiplas variáveis de uma só vez. É uma das minhas funções favoritas em EDA.

```
penguins |>
  rstatix::get_summary_stats(bill_length_mm:body_mass_g,
                             type = "full")
```

```
# A tibble: 4 x 13
  variable      n    min    max median    q1    q3    iqr    mad    mean
  sd
  <fct>      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
  <dbl>
1 bill_len~   342   32.1   59.6   44.4   39.2   48.5 9.28e0   7.04   43.9
5.46
2 bill_dep~   342   13.1   21.5   17.3   15.6   18.7 3.1 e0   2.22   17.2
1.98
3 flipper_~   342  172    231    197    190    213   2.3 e1   16.3   201.
14.1
4 body_mas~   342 2700   6300   4050   3550   4750   1.2 e3 890.   4202.
802.
# i 2 more variables: se <dbl>, ci <dbl>
```

Recomendo que deem uma boa olhada na documentação desta função para aproveitarem todo o seu potencial. No exemplo acima eu pedi as descritivas completas com o argumento `type = full` para todas as minhas variáveis numéricas utilizando a notação de intervalo do `tidyverse` com o argumento `bill_length_mm:body_mass_g`.

Como podem ver, a função me retorna o N, mínimo, máximo, mediana, quartis, IQR, média, desvio, erro padrão da média e intervalo de confiança.

## pastecs

A função `stat.desc()` nos fornece um rol completo de estatísticas descritivas para variáveis numéricas.

```
penguins |>
  select(bill_length_mm:body_mass_g) |>
  pastecs::stat.desc()
```

|          | bill_length_mm | bill_depth_mm | flipper_length_mm | body_mass_g  |
|----------|----------------|---------------|-------------------|--------------|
| nbr.val  | 3.420000e+02   | 342.000000    | 3.420000e+02      | 3.420000e+02 |
| nbr.null | 0.000000e+00   | 0.000000      | 0.000000e+00      | 0.000000e+00 |
| nbr.na   | 2.000000e+00   | 2.000000      | 2.000000e+00      | 2.000000e+00 |
| min      | 3.210000e+01   | 13.100000     | 1.720000e+02      | 2.700000e+03 |
| max      | 5.960000e+01   | 21.500000     | 2.310000e+02      | 6.300000e+03 |
| range    | 2.750000e+01   | 8.400000      | 5.900000e+01      | 3.600000e+03 |
| sum      | 1.502130e+04   | 5865.700000   | 6.871300e+04      | 1.437000e+06 |
| median   | 4.445000e+01   | 17.300000     | 1.970000e+02      | 4.050000e+03 |
| mean     | 4.392193e+01   | 17.1511696    | 2.009152e+02      | 4.201754e+03 |

|              |              |           |              |              |
|--------------|--------------|-----------|--------------|--------------|
| SE.mean      | 2.952205e-01 | 0.1067846 | 7.603704e-01 | 4.336473e+01 |
| CI.mean.0.95 | 5.806825e-01 | 0.2100394 | 1.495607e+00 | 8.529605e+01 |
| var          | 2.980705e+01 | 3.8998080 | 1.977318e+02 | 6.431311e+05 |
| std.dev      | 5.459584e+00 | 1.9747932 | 1.406171e+01 | 8.019545e+02 |
| coef.var     | 1.243020e-01 | 0.1151404 | 6.998830e-02 | 1.908618e-01 |

Para alterar a notação científica no resultado podemos usar `options(scipen = 999)`

```
options(scipen = 999)
```

```
penguins |>
```

```
  select(bill_length_mm:body_mass_g) |>
```

```
paste::stat.desc()
```

|              | bill_length_mm | bill_depth_mm | flipper_length_mm | body_mass_g     |
|--------------|----------------|---------------|-------------------|-----------------|
| nbr.val      | 342.0000000    | 342.0000000   | 342.0000000       | 342.0000000     |
| nbr.null     | 0.0000000      | 0.0000000     | 0.0000000         | 0.0000000       |
| nbr.na       | 2.0000000      | 2.0000000     | 2.0000000         | 2.0000000       |
| min          | 32.1000000     | 13.1000000    | 172.0000000       | 2700.0000000    |
| max          | 59.6000000     | 21.5000000    | 231.0000000       | 6300.0000000    |
| range        | 27.5000000     | 8.4000000     | 59.0000000        | 3600.0000000    |
| sum          | 15021.3000000  | 5865.7000000  | 68713.0000000     | 1437000.0000000 |
| median       | 44.4500000     | 17.3000000    | 197.0000000       | 4050.0000000    |
| mean         | 43.9219298     | 17.1511696    | 200.9152047       | 4201.7543860    |
| SE.mean      | 0.2952205      | 0.1067846     | 0.7603704         | 43.3647348      |
| CI.mean.0.95 | 0.5806825      | 0.2100394     | 1.4956068         | 85.2960539      |
| var          | 29.8070543     | 3.8998080     | 197.7317916       | 643131.0773267  |
| std.dev      | 5.4595837      | 1.9747932     | 14.0617137        | 801.9545357     |
| coef.var     | 0.1243020      | 0.1151404     | 0.0699883         | 0.1908618       |

```
options(scipen = 0)
```

E se quisermos retornar a configuração padrão `options(scipen = 0)`.

Outra maneira é salvar nossas descritivas em um objeto e formatá-lo posteriormente:

```
descritivas <- penguins |>
```

```
  select(bill_length_mm:body_mass_g) |>
```

```
paste::stat.desc()
```

```
format(descritivas, scientific = FALSE, digits = 2)
```

|              | bill_length_mm | bill_depth_mm | flipper_length_mm | body_mass_g |
|--------------|----------------|---------------|-------------------|-------------|
| nbr.val      | 342.00         | 342.00        | 342.00            | 342.00      |
| nbr.null     | 0.00           | 0.00          | 0.00              | 0.00        |
| nbr.na       | 2.00           | 2.00          | 2.00              | 2.00        |
| min          | 32.10          | 13.10         | 172.00            | 2700.00     |
| max          | 59.60          | 21.50         | 231.00            | 6300.00     |
| range        | 27.50          | 8.40          | 59.00             | 3600.00     |
| sum          | 15021.30       | 5865.70       | 68713.00          | 1437000.00  |
| median       | 44.45          | 17.30         | 197.00            | 4050.00     |
| mean         | 43.92          | 17.15         | 200.92            | 4201.75     |
| SE.mean      | 0.30           | 0.11          | 0.76              | 43.36       |
| CI.mean.0.95 | 0.58           | 0.21          | 1.50              | 85.30       |
| var          | 29.81          | 3.90          | 197.73            | 643131.08   |
| std.dev      | 5.46           | 1.97          | 14.06             | 801.95      |
| coef.var     | 0.12           | 0.12          | 0.07              | 0.19        |

## DescTools

De todos, o mais completo em EDA. Oferece além das estatísticas descritivas para variáveis numéricas, também contempla as categóricas. Além de fornecer ótimas visualizações das estatísticas. Pacote realmente muito bom!

```
DescTools::Desc(penguins)
```

```
Describe penguins (tbl_df, tbl, data.frame):
```

```
data frame: 344 obs. of 8 variables
  333 complete cases (96.8%)
```

| Nr | Class | ColName           | NAs       | Levels                               |
|----|-------|-------------------|-----------|--------------------------------------|
| 1  | fac   | species           | .         | (3): 1-Adelie, 2-Chinstrap, 3-Gentoo |
| 2  | fac   | island            | .         | (3): 1-Biscoe, 2-Dream, 3-Torgersen  |
| 3  | num   | bill_length_mm    | 2 (0.6%)  |                                      |
| 4  | num   | bill_depth_mm     | 2 (0.6%)  |                                      |
| 5  | int   | flipper_length_mm | 2 (0.6%)  |                                      |
| 6  | int   | body_mass_g       | 2 (0.6%)  |                                      |
| 7  | fac   | sex               | 11 (3.2%) | (2): 1-female, 2-male                |
| 8  | int   | year              | .         |                                      |


1 - species (factor)

| length | n      | NAs  | unique | levels | dupes |
|--------|--------|------|--------|--------|-------|
| 344    | 344    | 0    | 3      | 3      | y     |
|        | 100.0% | 0.0% |        |        |       |

|   | level     | freq | perc  | cumfreq | cumperc |
|---|-----------|------|-------|---------|---------|
| 1 | Adelie    | 152  | 44.2% | 152     | 44.2%   |
| 2 | Gentoo    | 124  | 36.0% | 276     | 80.2%   |
| 3 | Chinstrap | 68   | 19.8% | 344     | 100.0%  |

### 1 - species (factor)



paulo/2025-05-08

2 - island (factor)


| length | n      | NAs  | unique | levels | dupes |
|--------|--------|------|--------|--------|-------|
| 344    | 344    | 0    | 3      | 3      | y     |
|        | 100.0% | 0.0% |        |        |       |

|   | level  | freq | perc  | cumfreq | cumperc |
|---|--------|------|-------|---------|---------|
| 1 | Biscoe | 168  | 48.8% | 168     | 48.8%   |
| 2 | Dream  | 124  | 36.0% | 292     | 84.9%   |

```
3  Torgersen      52  15.1%      344  100.0%
```

## 2 – island (factor)



paulo/2025-05-08

## 3 – bill\_length\_mm (numeric)

| length | n     | NAs  | unique | 0s   | mean   | meanCI' |
|--------|-------|------|--------|------|--------|---------|
| 344    | 342   | 2    | 164    | 0    | 43.922 | 43.341  |
|        | 99.4% | 0.6% |        | 0.0% |        | 44.503  |

| .05    | .10    | .25    | median | .75    | .90    | .95    |
|--------|--------|--------|--------|--------|--------|--------|
| 35.700 | 36.600 | 39.225 | 44.450 | 48.500 | 50.800 | 51.995 |

| range  | sd    | vcoef | mad   | IQR   | skew  | kurt   |
|--------|-------|-------|-------|-------|-------|--------|
| 27.500 | 5.460 | 0.124 | 7.042 | 9.275 | 0.053 | -0.893 |


lowest : 32.1, 33.1, 33.5, 34.0, 34.1

highest: 55.1, 55.8, 55.9, 58.0, 59.6

' 95%-CI (classic)



### 3 – bill\_length\_mm (numeric)



### 4 – bill\_depth\_mm (numeric)


| length | n     | NAs   | unique | 0s    | mean  | meanCI' |
|--------|-------|-------|--------|-------|-------|---------|
| 344    | 342   | 2     | 80     | 0     | 17.15 | 16.94   |
|        | 99.4% | 0.6%  |        | 0.0%  |       | 17.36   |
| .05    | .10   | .25   | median | .75   | .90   | .95     |
| 13.90  | 14.30 | 15.60 | 17.30  | 18.70 | 19.50 | 20.00   |
| range  | sd    | vcoef | mad    | IQR   | skew  | kurt    |
| 8.40   | 1.97  | 0.12  | 2.22   | 3.10  | -0.14 | -0.92   |

lowest : 13.1, 13.2, 13.3, 13.4, 13.5 (2)

highest: 20.7 (3), 20.8, 21.1 (3), 21.2 (2), 21.5

' 95%-CI (classic)

#### 4 – bill\_depth\_mm (numeric)



#### 5 – flipper\_length\_mm (integer)


| length | n      | NAs    | unique | 0s     | mean   | meanCI' |
|--------|--------|--------|--------|--------|--------|---------|
| 344    | 342    | 2      | 55     | 0      | 200.92 | 199.42  |
|        | 99.4%  | 0.6%   |        | 0.0%   |        | 202.41  |
| .05    | .10    | .25    | median | .75    | .90    | .95     |
| 181.00 | 185.00 | 190.00 | 197.00 | 213.00 | 220.90 | 225.00  |
| range  | sd     | vcoef  | mad    | IQR    | skew   | kurt    |
| 59.00  | 14.06  | 0.07   | 16.31  | 23.00  | 0.34   | -1.00   |

lowest : 172, 174, 176, 178 (4), 179

highest: 226, 228 (4), 229 (2), 230 (7), 231

' 95%-CI (classic)

## 5 – flipper\_length\_mm (integer)



## 6 – body\_mass\_g (integer)


| length   | n        | NAs      | unique   | 0s       | mean     | meanCI'  |
|----------|----------|----------|----------|----------|----------|----------|
| 344      | 342      | 2        | 94       | 0        | 4'201.75 | 4'116.46 |
|          | 99.4%    | 0.6%     |          | 0.0%     |          | 4'287.05 |
| .05      | .10      | .25      | median   | .75      | .90      | .95      |
| 3'150.00 | 3'300.00 | 3'550.00 | 4'050.00 | 4'750.00 | 5'400.00 | 5'650.00 |
| range    | sd       | vcoef    | mad      | IQR      | skew     | kurt     |
| 3'600.00 | 801.95   | 0.19     | 889.56   | 1'200.00 | 0.47     | -0.74    |

lowest : 2'700, 2'850 (2), 2'900 (4), 2'925, 2'975

highest: 5'850 (3), 5'950 (2), 6'000 (2), 6'050, 6'300

' 95%-CI (classic)

6 – body\_mass\_g (integer)



7 – sex (factor - dichotomous)


| length | n     | NAs  | unique |
|--------|-------|------|--------|
| 344    | 333   | 11   | 2      |
|        | 96.8% | 3.2% |        |

|        | freq | perc  | lci.95 | uci.95' |
|--------|------|-------|--------|---------|
| female | 165  | 49.5% | 44.2%  | 54.9%   |
| male   | 168  | 50.5% | 45.1%  | 55.8%   |

' 95%-CI (Wilson)

## 7 – sex (factor – dichotomous)




## 8 – year (integer)

| length   | n        | NAs      | unique   | 0s       | mean     | meanCI'  |
|----------|----------|----------|----------|----------|----------|----------|
| 344      | 344      | 0        | 3        | 0        | 2'008.03 | 2'007.94 |
|          | 100.0%   | 0.0%     |          | 0.0%     |          | 2'008.12 |
| .05      | .10      | .25      | median   | .75      | .90      | .95      |
| 2'007.00 | 2'007.00 | 2'007.00 | 2'008.00 | 2'009.00 | 2'009.00 | 2'009.00 |
| range    | sd       | vcoef    | mad      | IQR      | skew     | kurt     |
| 2.00     | 0.82     | 0.00     | 1.48     | 2.00     | -0.05    | -1.51    |
| value    | freq     | perc     | cumfreq  | cumperc  |          |          |
| 1 2007   | 110      | 32.0%    | 110      | 32.0%    |          |          |
| 2 2008   | 114      | 33.1%    | 224      | 65.1%    |          |          |
| 3 2009   | 120      | 34.9%    | 344      | 100.0%   |          |          |

' 95%-CI (classic)

## 8 – year (integer)



Com certeza existem diversos outros pacotes que fazem as mesmas coisas ou até mais. Vale uma busca no CRAN ou na internet para encontrar pacotes que sejam adequados para seus objetivos. Se encontrar algum outro legal me avisa!

OLEKSY, A. Data Science with R. 2018.