


Análise de Variância

Paulo Barros

A Análise de Variância (ANOVA) é uma das ferramentas estatísticas mais influentes e amplamente utilizadas **na comparação de médias entre grupos**. Seu desenvolvimento é atribuído ao estatístico britânico Ronald A. Fisher, que a introduziu na década de 1920 como parte de seus trabalhos pioneiros em experimentação agrícola. Fisher buscava uma forma eficiente de **avaliar se diferenças observadas entre médias de grupos eram estatisticamente significativas ou se poderiam ser atribuídas apenas à variação aleatória**.

A grande contribuição de Fisher foi estruturar um método baseado na **decomposição da variabilidade total dos dados em componentes atribuíveis a diferentes fontes (como tratamento e erro)**, permitindo testar hipóteses sobre diferenças entre grupos com base na **razão entre essas variâncias**. Desde então, a ANOVA tornou-se essencial em diversas áreas do conhecimento — da biologia à engenharia, das ciências sociais às ciências da saúde — sempre que se deseja comparar múltiplos grupos sob um desenho experimental ou observacional controlado.



ANOVA

Análise de variância com um fator é uma técnica de teste de hipótese usada para comparar as médias de três ou mais populações. A análise de variância geralmente é abreviada como ANOVA.

Fontes de Variação (FV)	Graus de Liberdade (GL)	Soma de Quadrados (SQ)	Quadrado
Tratamento(entre)	$p - 1$	SQ_{Trat}	S
Erro Experimental(dentro)	$n - p$	SQ_{Res}	S
Total	$n - 1$	SQ_{Total}	

Como mencionado anteriormente, a ANOVA é um teste de razão de variâncias. O que a estatística do teste avalia de maneira resumida:

$$Estatística\ do\ Teste = \frac{Variancia\ dentro\ dos\ grupos}{Variancia\ entre\ grupos}$$

A variância entre as amostras mede as diferenças relacionadas ao tratamento/efeito atuando em cada amostra. Essa variância também é conhecida como **Quadrado Médio do Tratamento**.

Já a variância dentro das amostras mede as diferenças dentro da amostra, geralmente relacionadas com o erro amostral. Essa variância também é chamada de **Quadrado Médio do Resíduo**.

A **Estatística F** é o quociente destas duas variâncias, e nossa hipótese nula na ANOVA testa se a média dos grupos é igual:

$$H_0 : \mu_1 = \mu_2 = \dots \mu_n$$

Tabela da ANOVA

Esta é a famosa tabela da ANOVA, a mesma tabela que é retornada pelas funções que utilizaremos aqui no R. As somas de quadrado podem ser obtidas como:

$$SQ_{Total} = \sum_{i=1, j=1}^{I, J} Y_{ij}^2 - \frac{\left(\sum_{i=1, j=1}^{I, J} Y_{ij} \right)^2}{IJ}$$

$$SQ_{Trat} = \sum_{i=1}^I \frac{T_i^2}{J} - \frac{\left(\sum_{i=1, j=1}^{I, J} Y_{ij} \right)^2}{IJ}$$

$$SQ_{Total} = SQ_{Trat} + SQ_{Res}$$

Premissas da ANOVA:

1. As amostras devem ser independentes
2. As unidades amostrais são selecionadas aleatoriamente
3. Distribuição normal (gaussiana) dos resíduos
4. Homogeneidade da variância

Anova de um Fator

Para nossos exemplos práticos vamos utilizar os dados do pacote `palmerpenguins`. São dados morfométricos de diferentes espécies de pinguins coletados em diferentes ilhas.

Na ANOVA de um fator testamos o efeito de uma única variável categórica (Tratamento) sobre nossa variável dependente (y).

Pergunta: Existe diferença no tamanho do bico (`bill_length_mm`) entre as diferentes espécies de pinguim?

```
penguins <- palmerpenguins::penguins
```

```
penguins |>
  head()
```

```
# A tibble: 6 x 8
  species island    bill_length_mm bill_depth_mm
  <fct>   <fct>          <dbl>         <dbl>
  <int>     <int>
1 Adelie  Torgersen          39.1           18.7
181      3750
2 Adelie  Torgersen          39.5           17.4
186      3800
3 Adelie  Torgersen          40.3           18
195      3250
```

```

4 Adelie Torgersen      NA      NA
NA      NA
5 Adelie Torgersen      36.7     19.3
193     3450
6 Adelie Torgersen      39.3     20.6
190     3650
# i 2 more variables: sex <fct>, year <int>

```

Diferente da última sessão, utilizaremos a função `aov()` para realizarmos a ANOVA.

```

anova_bico <- aov(bill_length_mm ~ species, data =
  ↪ penguins)

```


Testando Premissas

Assim como fizemos com nosso modelo de regressão linear podemos avaliar nossos resíduos visualmente.

```

par(mfrow = c(2, 2), oma = c(0, 0, 2, 0))
plot(anova_bico)

```



Nossos resíduos parecem seguir normalidade e homocedasticidade. Mas podemos confirmar realizando os testes de Shapiro-Wilk (normalidade) e Bartlett (homocedasticidade).

```
shapiro.test(residuals(anova_bico))
```

Shapiro-Wilk normality test

```
data: residuals(anova_bico)
W = 0.98903, p-value = 0.01131
```

```
bartlett.test(bill_length_mm ~ species, data =
  ↪ penguins)
```

Bartlett test of homogeneity of variances

```
data: bill_length_mm by species
Bartlett's K-squared = 5.6179, df = 2, p-value =
0.06027
```

Lembrando que a hipótese nula em ambos os testes é de que os dados seguem normalidade/homocedasticidade. Confirmamos assim o nosso diagnóstico visual.

Tabela Anova

Listing 1 Tabela ANOVA

```
summary(anova_bico)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
species	2	7194	3597	410.6	<2e-16 ***
Residuals	339	2970	9		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

2 observations deleted due to missingness

E aqui obtemos a nossa tabela da ANOVA. E com base no p-valor obtido podemos confirmar que existe efeito de Espécie sobre o Tamanho do Bico dos Pinguins. Em relação a nossa hipótese nula, isso significa dizer que **pelo menos um dos grupos avaliados possui média diferente dos demais**.

Comparação de Médias

Uma vez sabendo que existe diferença significativa, agora precisamos realizar um pós-teste de comparação de médias entre os grupos. Para isso vamos utilizar o pacote `agricolae`. Este pacote é excelente por possuir diversos pos-testes para anova, entre eles Tukey, SNK, e Duncan.

Tukey HSD

O Teste **Tukey HSD** (*honestly significant difference*) é amplamente reconhecido por controlar de forma rigorosa a taxa de erro familiar, permitindo comparações par a par entre todas as médias com um critério bastante robusto.

```
agricolae::HSD.test(anova_bico,"species",
  ↪ group=TRUE, console=TRUE)
```

```
Study: anova_bico ~ "species"
```

```
HSD Test for bill_length_mm
```

```
Mean Square Error: 8.760732
```

```
species, means
```

		bill_length_mm			std	r	se
	Min	Max	Q25	Q50	Q75		
Adelie			38.79139	2.663405	151	0.2408694	
	32.1	46.0	36.75	38.80	40.750		
Chinstrap			48.83382	3.339256	68	0.3589349	
	40.9	58.0	46.35	49.55	51.075		

```
Gentoo          47.50488 3.081857 123 0.2668810
40.9 59.6 45.30 47.30 49.550
```

```
Alpha: 0.05 ; DF Error: 339
Critical Value of Studentized Range: 3.329136
```

```
Groups according to probability of means
differences and alpha level( 0.05 )
```

```
Treatments with the same letter are not
significantly different.
```

```
          bill_length_mm groups
Chinstrap    48.83382      a
Gentoo        47.50488      b
Adelie        38.79139      c
```

SNK

O Teste **Student-Newman-Keuls (SNK)** realiza comparações par a par de maneira sequencial, equilibrando a sensibilidade para detectar diferenças com um critério menos conservador que o Tukey HSD, mas mais rigoroso que o teste de Duncan.

```
agricolae::SNK.test(anova_bico, "species", group =
  ↪ TRUE, console = TRUE)
```

```
Study: anova_bico ~ "species"
```

```
Student Newman Keuls Test
for bill_length_mm
```

```
Mean Square Error: 8.760732
```

```
species, means
```

```
          bill_length_mm      std      r      se
Min Max    Q25    Q50    Q75
```

```

Adelie      38.79139 2.663405 151 0.2408694
32.1 46.0 36.75 38.80 40.750
Chinstrap   48.83382 3.339256  68 0.3589349
40.9 58.0 46.35 49.55 51.075
Gentoo      47.50488 3.081857 123 0.2668810
40.9 59.6 45.30 47.30 49.550

```

Groups according to probability of means
differences and alpha level(0.05)

Means with the same letter are not significantly
different.

```

          bill_length_mm groups
Chinstrap      48.83382      a
Gentoo         47.50488      b
Adelie         38.79139      c

```

Duncan

O Teste de **Duncan** adota uma abordagem mais liberal, facilitando a identificação de intervalos de similaridade entre as médias, mas com uma margem maior de risco de erro do Tipo I.

```

agricolae::duncan.test(anova_bico, "species", group
↪  = TRUE, console = TRUE)

```

Study: anova_bico ~ "species"

Duncan's new multiple range test
for bill_length_mm

Mean Square Error: 8.760732

species, means

```

          bill_length_mm      std      r      se
Min  Max    Q25    Q50    Q75

```



```

Adelie          38.79139 2.663405 151 0.2408694
32.1 46.0 36.75 38.80 40.750
Chinstrap       48.83382 3.339256  68 0.3589349
40.9 58.0 46.35 49.55 51.075
Gentoo          47.50488 3.081857 123 0.2668810
40.9 59.6 45.30 47.30 49.550

```

Groups according to probability of means
differences and alpha level(0.05)

Means with the same letter are not significantly
different.

	bill_length_mm	groups
Chinstrap	48.83382	a
Gentoo	47.50488	b
Adelie	38.79139	c

Dunnett

O Teste **Dunnett** é particularmente útil quando o objetivo principal é comparar cada tratamento com um grupo de controle, focando essa análise e ajustando as comparações para esse propósito.

Para realizar esse teste usaremos o pacote `multcomp`.

```

multcomp::glht(anova_bico, linfct =
  ↪ multcomp::mcp(species= "Dunnett"))

```

General Linear Hypotheses

Multiple Comparisons of Means: Dunnett Contrasts

Linear Hypotheses:

	Estimate
Chinstrap - Adelie == 0	10.042
Gentoo - Adelie == 0	8.713

Apresentando os resultados

Além da apresentação da Listing 1 podemos reportar nossos resultados graficamente com boxplots e adicionar os grupos do teste de Tukey.

```
library(ggtext)

grupos <- tibble(species = factor(c("Adelie",
  ↪ "Chinstrap", "Gentoo")),
                 grupos = c("C","A","B"),
                 ymax = c(48,59,58))

tukey <- tibble(species = "Adelie",
                 label = "<b>TukeyHSD</b><br>MSE:
  ↪ 8.76<br>p <
  ↪ 0.05<br>q<sub>a</sub>: 3.329",
                 y = 55)

penguins |>
  ggplot(aes(x=species, y=bill_length_mm, fill =
  ↪ species)) +
  geom_boxplot(outliers = FALSE)+
  annotate("text", x=grupos$species,
           y = grupos$ymax,
           label = grupos$grupos,
           family = "Ubuntu",
           size = 5) +
  geom_richtext(data = tukey, aes(x = species, y =
  ↪ 55, label = label),
               fill = NA) +
  theme_classic(base_size = 14, base_family =
  ↪ "Ubuntu") +
  theme(legend.position = "none") +
  labs(title = "Variação do Comprimento de Bico em
  ↪ Pinguins",
       x = "Espécies",
       y = "Comprimento do Bico (mm)")
```

Warning: Removed 2 rows containing non-finite
outside the scale range
(`stat\_boxplot()`).

